

Peramalan Harga Minyak Goreng dan Tepung Terigu Indonesia

Asian Development Bank

Bekerja sama dengan Kementerian Perdagangan Indonesia

September - October 2024

1 Asesmen

Perkiraan dan peramalan harga komoditas yang akurat sangat penting untuk menjaga stabilitas pasar dan memberikan informasi bagi pengambilan keputusan kebijakan. Metode Kementerian Perdagangan dalam memperkirakan harga nasional minyak goreng dan tepung terigu telah menjadi subjek penilaian ini, berdasarkan diskusi mengenai praktik Kementerian saat ini dan area yang memerlukan peningkatan. Temuan menunjukkan adanya kesenjangan yang signifikan dalam metode peramalan mereka, ketergantungan pada analisis kualitatif, dan kurangnya integrasi data, yang secara keseluruhan menghambat akurasi dalam penilaian harga mereka.

Kementerian Perdagangan saat ini belum menggunakan model peramalan formal untuk memprediksi harga nasional minyak goreng dan tepung terigu. Sebaliknya, pendekatan mereka terbatas pada mengandalkan kontrak harga masa depan yang berasal dari kesepakatan pasar. Kontrak-kontrak ini memberikan wawasan tentang pergerakan harga berdasarkan ekspektasi pasar, tetapi tidak mempertimbangkan data harga nasional yang sesungguhnya. Dengan tidak mengintegrasikan informasi harga nasional secara real-time atau historis untuk komoditas ini, perkiraan Kementerian menjadi kurang akurat secara inheren. Model peramalan, seperti yang menggunakan teknik ekonometrika, sangat penting untuk memprediksi tren harga dari waktu ke waktu dan memberikan dasar yang lebih andal bagi pengambilan keputusan kebijakan.

Selain ketiadaan metode peramalan kuantitatif, analisis pergerakan harga oleh Kementerian Perdagangan sebagian besar bersifat kualitatif. Mereka menilai dampak isu-isu internasional dan nasional—seperti ketegangan geopolitik, perubahan kebijakan, atau perubahan permintaan pasar—terhadap harga minyak goreng dan tepung terigu tanpa membangun hubungan kuantitatif yang langsung antara faktor eksternal ini dan harga nasional. Meskipun penilaian kualitatif memberikan wawasan kontekstual yang berharga, penilaian ini tidak menawarkan pengukuran yang tepat tentang bagaimana peristiwa atau masalah tertentu memengaruhi harga domestik. Tanpa keterkaitan kuantitatif semacam itu, menjadi sulit untuk mengukur dampak nyata dari tekanan eksternal terhadap harga komoditas, yang membatasi kemampuan Kementerian untuk merumuskan intervensi yang efektif dan tepat waktu.

Salah satu area di mana Kementerian telah membuat kemajuan adalah dalam memperkirakan koefisien variasi di berbagai wilayah dan periode, sebuah langkah yang dapat meningkatkan pemahaman tentang volatilitas harga di pasar minyak goreng dan tepung terigu. Namun, koefisien ini tidak langsung terhubung dengan perkiraan harga nasional. Koefisien variasi dapat memberikan wawasan sub-

stansial tentang bagaimana harga berfluktuasi dari waktu ke waktu atau antarwilayah yang berbeda, tetapi dengan tidak mengintegrasikannya ke dalam model harga, Kementerian kehilangan alat berharga yang dapat meningkatkan ketahanan perkiraan harga mereka. Kurangnya integrasi ini berarti bahwa perkiraan harga nasional tidak memperhitungkan variabilitas yang melekat di pasar regional atau waktu perubahan harga.

Lebih lanjut, keberagaman harga lokal secara signifikan memengaruhi harga nasional minyak goreng dan tepung terigu. Komoditas-komoditas ini tunduk pada kondisi penawaran dan permintaan lokal yang bervariasi, biaya distribusi, dan dinamika pasar regional, yang menciptakan variasi harga di berbagai wilayah di negara ini. Metode perkiraan Kementerian saat ini tidak cukup menangani disparitas harga lokal ini. Misalnya, biaya minyak goreng di pasar perkotaan dengan rantai pasok yang kuat dapat sangat berbeda dari biaya di daerah terpencil, di mana tantangan logistik meningkatkan harga. Kegagalan untuk mempertimbangkan keberagaman ini saat memperkirakan harga nasional dapat menyebabkan ketidakakuratan dan keputusan kebijakan yang salah, yang mengabaikan perbedaan regional yang penting. Model yang lebih canggih akan mempertimbangkan variasi lokal ini dan memberikan harga nasional tertimbang yang mencerminkan realitas pasar yang berbeda.

Dinamika harga minyak goreng sangat kompleks karena pengaruh berbagai jenis pasar dan kebijakan pemerintah. Di Indonesia, minyak goreng diklasifikasikan ke dalam tiga jenis utama: minyak kemasan, minyak curah, dan Minyak Goreng KITA. Kebijakan Domestic Price Obligation (DPO) dan Domestic Market Obligation (DMO) Kementerian memainkan peran penting dalam menentukan harga minyak goreng. DPO menetapkan harga tetap untuk minyak goreng dari produsen ke pengecer, berdasarkan biaya produksi, harga Crude Palm Oil (CPO) di pelabuhan utama seperti Dumai dan Belawan, serta margin keuntungan untuk produsen. Harga DPO ditetapkan oleh Kementerian, memastikan beberapa tingkat kontrol harga.

Demikian pula, kebijakan DMO mengharuskan produsen minyak goreng untuk memasok kuota produksi mereka ke pasar domestik sebelum mereka dapat mengekspor, yang membantu memastikan ketersediaan stok nasional yang cukup dan menstabilkan harga lokal. Namun, kebijakan-kebijakan ini memiliki pengaruh terbesar pada harga Minyak Goreng KITA, minyak goreng yang dikendalikan pemerintah, dibandingkan dengan minyak curah dan kemasan, di mana kekuatan pasar memainkan peran lebih besar. Metode perkiraan Kementerian tidak sepenuhnya menangkap bagaimana mekanisme harga yang berbeda ini memengaruhi setiap jenis minyak goreng. Mengingat kompleksitas yang diperkenalkan oleh kebijakan DPO dan DMO, pendekatan yang lebih bernuansa diperlukan untuk membedakan dampak pada berbagai kategori produk ini.

Salah satu kekurangan utama dalam pendekatan Kementerian saat ini adalah kurangnya eksplorasi data. Eksplorasi data, yang melibatkan pemeriksaan tren harga historis, fluktuasi pasar, dan variabel relevan lainnya, adalah langkah penting dalam memahami faktor-faktor yang mendasari yang mendorong perubahan harga. Ini memberikan dasar untuk menciptakan model prediktif yang didasarkan pada pola data dunia nyata. Sayangnya, Kementerian belum melakukan eksplorasi data sistematis terkait harga nasional minyak goreng dan tepung terigu. Kurangnya keterlibatan dengan data ini membatasi kemampuan mereka untuk menciptakan model peramalan yang kuat, dan hal ini membuat mereka bergantung pada metode kualitatif yang kurang presisi. Tanpa wawasan berbasis data, Kementerian kurang siap untuk membuat keputusan yang tepat atau mengantisipasi pergerakan harga

yang signifikan.

Kesimpulannya, metode Kementerian Perdagangan saat ini untuk memperkirakan harga minyak goreng dan tepung terigu tidak memadai untuk memberikan peramalan yang akurat dan panduan kebijakan yang tepat. Ketiadaan model peramalan formal, ketergantungan pada analisis kualitatif, kegagalan untuk mengintegrasikan koefisien variasi, dan pengabaian terhadap keragaman harga lokal semuanya berkontribusi pada keterbatasan dalam pendekatan mereka. Selain itu, kurangnya eksplorasi data oleh Kementerian mencegah mereka memanfaatkan data historis dan real-time yang dapat memberikan pemahaman yang lebih komprehensif tentang dinamika pasar.

2 Tinjauan Pustaka

2.1 Peramalan Harga

Peramalan harga merupakan salah satu bidang yang terus mengalami perkembangan, terutama dengan meningkatnya ketersediaan data besar dan metode pemodelan canggih. Penelitian-penelitian terbaru menunjukkan bahwa pendekatan berbasis pembelajaran mesin dan model non-linear mampu memberikan hasil yang kompetitif dibandingkan pendekatan tradisional.

Hauzenberger et al. (2023) mengevaluasi efektivitas teknik reduksi dimensi non-linear dalam peramalan inflasi secara real-time. Mereka memanfaatkan metode pembelajaran mesin seperti Autoencoder dan squared principal components untuk menghasilkan faktor laten yang berkorelasi dengan inflasi. Hasil penelitian menunjukkan bahwa metode ini sangat kompetitif dibandingkan pendekatan linier seperti principal components analysis, terutama selama episode resesi atau pandemi COVID-19.

Araujo dan Gaglianone (2023) mengeksplorasi metode pembelajaran mesin untuk meningkatkan peramalan inflasi di Brasil. Dengan menggunakan database besar yang terdiri dari 501 seri dan 50 metode peramalan, hasil penelitian mereka menunjukkan bahwa metode seperti random forest dan xgboost mampu mengungguli model ekonometrik tradisional dalam beberapa kasus. Penelitian ini juga menyoroti adanya non-linearitas yang relevan dalam dinamika inflasi.

Almosova dan Andresen (2023) menginvestigasi kemampuan jaringan saraf rekuren (LSTM) dalam peramalan inflasi bulanan di AS. Meskipun LSTM sedikit lebih unggul dibandingkan model autoregressive (AR), neural network (NN), dan Markov-switching, kinerjanya setara dengan model SARIMA. Penelitian ini memberikan analisis sensitivitas terhadap hyperparameter serta interpretasi kualitatif dari apa yang dipelajari oleh jaringan saraf tersebut.

Barkan et al. (2023) mengembangkan arsitektur hierarkis berbasis jaringan saraf rekuren untuk memprediksi komponen inflasi dari Consumer Price Index (CPI). Dengan menggunakan dataset besar dari US CPI-U, model Hierarchical Recurrent Neural Network (HRNN) menunjukkan keunggulan signifikan dibandingkan pendekatan peramalan inflasi lainnya, terutama pada level yang lebih volatil.

Cornand dan Hubert (2020) mendokumentasikan validitas eksternal dari ekspektasi inflasi eksperimental dibandingkan dengan lima kategori ekspektasi lapangan. Studi ini menemukan bahwa kesalahan peramalan memiliki pola yang serupa antar kategori, menunjukkan adanya bounded rationality atau ketidaksempurnaan informasi. Lagged inflation secara konsisten memengaruhi pembentukan ekspektasi inflasi.

McKnight et al. (2020) mengembangkan prosedur peramalan berbasis New Keynesian Phillips

Curve dengan tren inflasi yang bervariasi sepanjang waktu. Dengan data kuartalan untuk Euro Area dan AS, mereka menunjukkan bahwa pendekatan berbasis teori ini mengungguli model time series populer, menunjukkan pentingnya peran teori dalam peramalan inflasi.

Aparicio dan Bertolotto (2020) menggunakan indeks harga online untuk memprediksi Consumer Price Index (CPI). Mereka menemukan bahwa indeks harga online dapat mengantisipasi perubahan tren inflasi resmi lebih dari satu bulan sebelumnya, serta mampu mengungguli survei Bloomberg dalam hal peramalan inflasi bulanan dan triwulanan.

Zhang et al. (2020) memperkenalkan model volatilitas stokastik dengan inovasi ARMA untuk memprediksi inflasi di negara-negara G7. Penelitian ini menunjukkan bahwa model ini kompetitif dalam peramalan inflasi, terutama di negara-negara seperti Kanada, Prancis, Italia, dan AS.

Medeiros et al. (2021) mengeksplorasi metode pembelajaran mesin dalam lingkungan data yang kaya untuk memprediksi inflasi AS. Mereka menunjukkan bahwa random forest secara konsisten lebih akurat dibandingkan benchmark lainnya, berkat seleksi variabel dan potensi non-linearitas antara variabel makroekonomi kunci dengan inflasi.

Mertens dan Nason (2020) mempelajari dinamika bersama antara inflasi AS dan prediksi inflasi profesional. Penelitian mereka menunjukkan bahwa prediksi inflasi dengan informasi yang lengket semakin jarang diperbarui sejak 1990, bersamaan dengan menurunnya peran kejutan yang persisten dalam menjelaskan pergerakan inflasi.

Nasir (2020) menyoroti pentingnya kesederhanaan dalam peramalan inflasi di tengah ketidakpastian tinggi. Studi ini menunjukkan bahwa model sederhana seperti ARIMA lebih efektif dibandingkan pendekatan kompleks dalam lingkungan pasca-Brexit.

Nason dan Smith (2021) mengukur tren evolusi lambat dalam inflasi AS dengan menggunakan prediksi dari Survey of Professional Forecasters (SPF). Mereka menemukan bahwa tren inflasi cenderung konvergen ke 2% dan volatilitasnya menurun seiring waktu.

Bañbura dan Bobeica (2023) meneliti apakah Phillips Curve membantu peramalan inflasi di zona euro. Penelitian mereka menunjukkan bahwa model generasi baru dengan fitur time-varying mampu memberikan peramalan yang lebih baik dibandingkan benchmark univariat.

Macias et al. (2023) menggunakan data harga online yang sangat besar untuk nowcasting inflasi makanan di Polandia. Kerangka kerja mereka menunjukkan bahwa data harga online mampu memberikan keakuratan nowcasting yang lebih baik dibandingkan metode tradisional, terutama setelah pandemi COVID-19.

Eickmeier dan Ziegler (2008) menggunakan meta-analisis untuk mengevaluasi keberhasilan model faktor dinamis dalam peramalan output dan inflasi. Mereka menemukan bahwa ukuran dataset dan teknik estimasi faktor memengaruhi kinerja model ini secara signifikan.

Wang et al. (2020) mengulas tren penelitian dalam metode peramalan harga produk pertanian. Mereka menekankan pentingnya model hybrid, penyesuaian musiman, dan algoritma optimasi untuk meningkatkan kinerja model di masa depan.

2.2 Dynamic Factor Model

Analisis faktor adalah teknik reduksi dimensi yang merangkum sumber variasi di antara variabel-variabel. Metode ini pertama kali diperkenalkan dalam literatur psikologi oleh Spearman (1904),

yang menggunakan variabel yang tidak teramati, atau faktor, untuk menjelaskan kemampuan kognitif individu. Awalnya dikembangkan untuk vektor acak yang terdistribusi secara independen, Geweke (1977) memperluas metode ini untuk menangkap keterkaitan dalam deret waktu ekonomi. Konsep bahwa keterkaitan serangkaian data ekonomi makro dapat dikaitkan dengan siklus bisnis pertama kali diusulkan oleh Burns dan Mitchell (1946): “suatu siklus terdiri dari ekspansi yang terjadi hampir bersamaan di banyak kegiatan ekonomi, diikuti oleh resesi umum, kontraksi, dan kebangkitan yang akhirnya menyatu ke dalam fase ekspansi dari siklus berikutnya; urutan perubahan ini berulang tetapi tidak periodik.”

Aplikasi awal model faktor dinamis (DFM) pada data makroekonomi, termasuk karya Sargent dan Sims (1977) serta Stock dan Watson (1989, 1991, 1993), menunjukkan bahwa sejumlah kecil faktor laten dapat menjelaskan banyak dari perilaku dinamis agregat ekonomi utama. Secara khusus, model faktor tunggal dinamis dapat merangkum vektor indikator makroekonomi, dengan faktor yang bertindak sebagai indeks kondisi ekonomi yang mencirikan siklus bisnis. Dalam studi-studi ini, dataset mengandung lebih banyak periode waktu daripada variabel, dan identifikasi faktor memerlukan asumsi yang relatif ketat. Sementara dimensi waktu dibatasi oleh perjalanan waktu, ketersediaan indikator ekonomi makro dan keuangan yang semakin meningkat memungkinkan perluasan dataset dalam dimensi cross-sectional, yang memungkinkan asumsi-asumsi yang lebih longgar.

Chamberlain (1983) dan Chamberlain dan Rothschild (1983) menerapkan model faktor pada panel data keuangan yang luas, memfasilitasi perkembangan lebih lanjut model faktor dinamis dalam makroekonometrika. Sejak tahun 2000-an, DFM telah banyak digunakan untuk menganalisis dataset makroekonomi besar, yang terkadang terdiri dari ratusan deret dengan ratusan pengamatan pada setiap deret. Model-model ini sangat berharga dalam mensintesis informasi dari variabel yang diamati pada frekuensi berbeda, memperkirakan siklus bisnis laten, nowcasting dan forecasting, serta memperkirakan probabilitas resesi dan titik balik. Seperti yang dikatakan Diebold (2003), meskipun DFM “tidak menganalisis Big Data yang sesungguhnya, mereka jelas mewakili sebuah gerakan makroekonometrika ke arah itu,” dan gerakan ini telah sangat produktif.

Beberapa ulasan yang sangat baik tentang model faktor dinamis telah diterbitkan, termasuk Bai dan Ng (2008), Bai dan Wang (2016), Barigozzi (2018), Barhoumi, Darné, dan Ferrara (2014), Breitung dan Eickmeier (2006), Lütkepohl (2014), serta Stock dan Watson (2006, 2011, 2016).

2.3 Perbaikan di Masa Depan

Untuk meningkatkan kemampuan peramalan Kementerian Perdagangan, Dynamic Factor Modelling (DFM) menyediakan kerangka kerja yang ideal untuk mengatasi keterbatasan saat ini dalam memperkirakan harga minyak goreng dan tepung terigu. DFM sangat berguna dalam situasi di mana sejumlah besar variabel yang dapat diamati memengaruhi beberapa faktor mendasar yang menggerakkan sistem. Dengan menerapkan DFM, Kementerian dapat menangkap tren umum di berbagai indikator ekonomi, seperti harga komoditas global, nilai tukar, biaya transportasi, data produksi domestik, dan pola cuaca, untuk meramalkan harga nasional minyak goreng dan tepung terigu dengan lebih akurat.

Salah satu kekuatan utama DFM adalah kemampuannya untuk mengurangi dimensi dari suatu dataset dengan mengekstraksi beberapa faktor umum yang menjelaskan sebagian besar variasi dalam data yang diamati. Hal ini memungkinkan Kementerian untuk mengintegrasikan berbagai variabel,

seperti data harga regional, tren pasar internasional, perubahan kebijakan, dan kondisi penawaran-permintaan lokal, ke dalam model peramalan yang terpadu. Dengan demikian, model ini akan bergerak melampaui ketergantungan pada kontrak harga masa depan dan penilaian kualitatif, menyediakan metode berbasis data yang kuat untuk memprediksi tren harga sambil memperhitungkan dinamika nasional dan internasional.

DFM juga sangat cocok untuk menangani sifat dinamis dari harga komoditas, di mana beberapa faktor berinteraksi dari waktu ke waktu. Melalui metode ini, Kementerian dapat memodelkan dampak yang berubah-ubah dari berbagai penggerak ekonomi, termasuk kebijakan Domestic Market Obligation (DMO) dan Domestic Price Obligation (DPO), yang mempengaruhi harga minyak goreng secara berbeda di berbagai kategori produk. DFM dapat secara efisien memperhitungkan fluktuasi yang dipicu oleh kebijakan ini, meningkatkan presisi perkiraan harga dan memungkinkan respons kebijakan yang lebih baik. Fleksibilitas model untuk menggabungkan efek jangka pendek dan jangka panjang memungkinkan peramalan pergerakan harga yang lebih akurat dan tepat waktu.

Selain itu, kemampuan DFM untuk mengintegrasikan keragaman harga lokal ke dalam proses peramalan sangatlah bermanfaat. Mengingat variasi harga regional yang diamati di seluruh Indonesia, faktor-faktor dinamis dapat digunakan untuk menangkap heterogenitas dalam rantai pasok, biaya transportasi, dan kondisi pasar di berbagai wilayah. Ini akan menghasilkan perkiraan harga nasional yang lebih rinci dan representatif, memastikan bahwa disparitas regional secara akurat tercermin dalam perkiraan keseluruhan. Dengan memanfaatkan kekuatan DFM, Kementerian dapat menciptakan model komprehensif yang tidak hanya memprediksi tren harga tetapi juga memberikan wawasan berharga tentang faktor-faktor yang mendasari perubahan harga, memfasilitasi pengambilan keputusan yang lebih baik.

Seperti yang diidentifikasi dalam tinjauan pustaka, model faktor dinamis telah berhasil diterapkan untuk memprediksi inflasi, harga komoditas, dan indikator ekonomi lainnya dalam berbagai konteks geografis dan pasar. Studi seperti Hauzenberger et al. (2023) menunjukkan bahwa penggunaan teknik reduksi dimensi non-linear, seperti Autoencoder dan squared principal components, dapat meningkatkan akurasi peramalan inflasi secara real-time, terutama selama periode resesi atau krisis global seperti pandemi COVID-19. Araujo dan Gaglianone (2023) mengeksplorasi metode pembelajaran mesin dalam memprediksi inflasi di Brasil, menunjukkan bahwa integrasi data yang besar dengan model seperti random forest mampu menangkap non-linearitas yang relevan untuk peramalan inflasi.

Almosova dan Andresen (2023) menggarisbawahi keunggulan jaringan saraf rekuren (LSTM) dalam memprediksi inflasi bulanan dengan efisiensi yang sebanding dengan model SARIMA, sementara Barkan et al. (2023) memperkenalkan model Hierarchical Recurrent Neural Network (HRNN) yang secara signifikan meningkatkan akurasi peramalan komponen inflasi dalam indeks harga konsumen (CPI) dengan memanfaatkan hierarki data. Medeiros et al. (2021) menekankan manfaat pembelajaran mesin dalam lingkungan data yang kaya, dengan model random forest yang secara konsisten menghasilkan prediksi inflasi yang unggul berkat kemampuan model ini untuk menangkap hubungan non-linear antara variabel makroekonomi.

Zhang et al. (2020) memperkenalkan model volatilitas stokastik dengan inovasi ARMA, yang secara efektif meningkatkan peramalan inflasi di negara-negara G7, sementara Macias et al. (2023) menunjukkan bahwa data harga online dapat digunakan untuk nowcasting inflasi makanan dengan

akurasi yang meningkat secara signifikan selama pandemi COVID-19. Cornand dan Hubert (2020) mendokumentasikan kesamaan pola ekspektasi inflasi dari berbagai sumber data, menunjukkan bahwa hubungan antara variabel eksternal dan inflasi sering kali didasarkan pada bounded rationality yang dapat dimodelkan melalui pendekatan faktor.

Eickmeier dan Ziegler (2008) menggunakan meta-analisis untuk menilai keberhasilan model faktor dinamis dalam peramalan inflasi, menunjukkan bahwa model ini lebih unggul dibandingkan model tradisional ketika diterapkan pada dataset besar. Wang et al. (2020) memberikan pandangan tentang bagaimana kombinasi model dan penyesuaian musiman dapat meningkatkan peramalan harga komoditas pertanian.

Penelitian-penelitian ini menggarisbawahi kemampuan model faktor dinamis untuk memanfaatkan data besar dalam memberikan peramalan yang lebih akurat, khususnya pada pasar yang melibatkan dinamika kompleks dan variabel-variabel yang saling bergantung. Mengingat dinamika harga minyak goreng dan tepung terigu yang dipengaruhi oleh berbagai faktor, DFM adalah pilihan yang logis untuk meningkatkan akurasi peramalan.

3 Metode

3.1 Dari Extract ke Approximate Factor Models

Dalam sebuah factor model, korelasi di antara n variabel, $x_1, \dots, x_n$, yang memiliki T observasi, diasumsikan sepenuhnya disebabkan oleh beberapa, $r < n$, variabel laten yang tidak teramati, yang disebut sebagai factors. Hubungan antara variabel yang dapat diamati dan factors diasumsikan bersifat linear. Dengan demikian, setiap observasi x_{it} dapat didekomposisi sebagai

$$x_{it} = \mu_i + \lambda_i' f_t + \epsilon_{it}, \quad (1)$$

di mana μ_i adalah rata-rata dari x_i , λ_i adalah vektor $r \times 1$, dan ϵ_{it} dan f_t adalah dua proses yang tidak berkorelasi. Dengan demikian, untuk $i = 1, \dots, n$ dan $t = 1, \dots, T$, x_{it} didekomposisi menjadi jumlah dari dua komponen yang tidak teramati dan saling ortogonal: komponen umum, $\chi_{it} = \lambda_i' f_t$, dan komponen idiosinkratik, $\xi_{it} = \mu_i + \epsilon_{it}$. Sementara factors menggerakkan komponen umum, komponen idiosinkratik digerakkan oleh karakteristik unik dari masing-masing variabel.

Korelasi antara x_i dan x_j , dengan $j \neq i$, pada komponen idiosinkratik muncul dari karakteristik yang spesifik terhadap variabel x_i masing-masing. Asumsi lebih lanjut yang ditempatkan pada dua komponen yang tidak teramati ini menghasilkan berbagai tipe factor models.

3.2 Exact Factor Models

Exact factor model diperkenalkan oleh Spearman (1904). Model ini mengasumsikan bahwa komponen idiosinkratik tidak berkorelasi pada setiap lead dan lag sehingga ξ_{it} dan ξ_{ks} bersifat ortogonal secara mutual untuk semua $k \neq i$ dan sembarang s dan t , sehingga semua korelasi di antara variabel yang dapat diamati didorong oleh factors. Model ini dapat ditulis sebagai

$$x_{it} = \mu_i + \sum_{j=1}^r \lambda_{ij} f_{jt} + e_{it}, \quad i = 1, \dots, n, t = 1, \dots, T, \quad (2)$$

di mana f_{jt} dan e_{it} adalah white noises yang ortogonal untuk setiap i dan j ; e_{it} dan e_{kt} adalah ortogonal untuk $k \neq i$; dan λ_{ij} adalah loading dari faktor ke- j pada variabel ke- i . Persamaan (1) juga dapat ditulis sebagai

$$x_{it} = \mu_i + \lambda'_i f_t + e_{it}, \quad i = 1, \dots, n, t = 1, \dots, T, \quad (3)$$

dengan $\lambda'_i = (\lambda_{i1}, \dots, \lambda_{ir})$ dan $f_t = (f_{1t}, \dots, f_{rt})'$. Komponen umum adalah $\chi_{it} = \sum_{j=1}^r \lambda_{ij} f_{jt}$, dan komponen idiosinkratik adalah $\xi_{it} = \mu_i + e_{it}$.

Dalam notasi matriks, dengan $x_t = (x_{1t}, \dots, x_{nt})'$, $f_t = (f_{1t}, \dots, f_{rt})'$, dan $e_t = (e_{1t}, \dots, e_{nt})'$, model dapat ditulis sebagai

$$x_t = \mu + \Lambda f_t + e_t, \quad (4)$$

di mana $\Lambda = (\lambda_1, \dots, \lambda_n)'$ adalah matriks $n \times r$ dengan full column rank (jika tidak, lebih sedikit factors akan cukup), dan matriks kovarian e_t adalah diagonal karena komponen idiosinkratik diasumsikan tidak berkorelasi. Observasi yang tersedia untuk $t = 1, \dots, T$ dapat ditumpuk, dan Pers. (4) dapat ditulis ulang sebagai

$$X = 1_T \otimes \mu' + F \Lambda' + E, \quad (5)$$

di mana $X = (x_1, \dots, x_T)'$ adalah matriks $T \times n$, $F = (f_1, \dots, f_T)'$ adalah matriks $T \times r$, $E = (e_1, \dots, e_T)'$ adalah matriks $T \times n$, dan 1_T adalah vektor $T \times 1$ dengan komponen bernilai 1.

Meskipun asumsi utama di balik factor models adalah bahwa dua proses f_t dan e_t ortogonal satu sama lain, exact static factor model lebih lanjut mengasumsikan bahwa komponen idiosinkratik juga ortogonal satu sama lain, sehingga setiap korelasi antara variabel yang dapat diamati hanya disebabkan oleh factors umum.

Kedua asumsi ortogonalitas ini diperlukan untuk memastikan identifiabilitas model (lihat Anderson, 1984; Bartholomew, 1987). Perlu dicatat bahwa f_t hanya didefinisikan hingga premultiplication oleh matriks invertibel Q karena f_t dapat digantikan oleh $Q f_t$ setiap kali Λ digantikan oleh ΛQ^{-1} . Ini berarti bahwa hanya ruang yang masing-masing terbentang oleh f_t dan Λ yang didefinisikan secara unik. Masalah ketidakpastian factors ini harus diperhitungkan pada tahap estimasi.

Factor models telah diperkenalkan dalam ekonomi oleh Geweke (1977), Sargent dan Sims (1977), serta Engle dan Watson (1981). Para penulis ini menggeneralisasi model di atas untuk menangkap dinamika dalam data. Menggunakan notasi yang sama seperti pada Pers. (4), dynamic exact factor model dapat ditulis sebagai

$$x_t = \mu + \Lambda_0 f_t + \Lambda_1 f_{t-1} + \dots + \Lambda_s f_{t-s} + e_t, \quad (6)$$

atau lebih ringkas

$$x_t = \mu + \Lambda(L)f_t + e_t, \quad (7)$$

di mana L adalah operator lag.

Dalam model ini, f_t dan e_t tidak lagi diasumsikan sebagai white noises, tetapi diizinkan untuk menjadi proses dinamis yang berkorelasi sendiri yang berkembang sesuai dengan $f_t = \Psi(L)u_t$ dan $e_t = \rho(L)\epsilon_t$, di mana vektor berdimensi q dan n , masing-masing, u_t dan ϵ_t , mengandung kesalahan iid. Dimensi dari f_t juga q , yang oleh karena itu disebut sebagai jumlah dari factors dinamis. Dalam kebanyakan literatur dynamic factor models, f_t dan e_t umumnya diasumsikan sebagai proses stasioner, sehingga jika diperlukan, variabel yang dapat diamati diproses ulang untuk menjadi stasioner.

Model ini memiliki representasi statis

$$x_t = \mu + \Lambda F_t + e_t, \quad (8)$$

dengan $F_t = (f'_t, f'_{t-1}, \dots, f'_{t-s})'$, vektor berdimensi $r = q(1+s)$ dari static factors, dan $\Lambda = (\Lambda_0, \Lambda_1, \dots, \Lambda_s)$, matriks $n \times r$ dari loading coefficients. Representasi dinamis dalam persamaan (1) dan persamaan (7) secara eksplisit menangkap ketergantungan variabel yang diamati pada lags dari factors, sementara representasi statis menyematkan dinamika tersebut secara implisit. Kedua bentuk ini mengarah pada metode estimasi yang berbeda yang akan dibahas di bawah ini.

Exact dynamic factor models mengasumsikan bahwa dimensi cross-sectional dari dataset, $n < T$, adalah terbatas, dan biasanya digunakan dengan sampel kecil, $n \ll T$. Ada dua alasan mengapa model-model ini diabaikan dalam kasus $n \rightarrow \infty$. Pertama, estimasi maximum likelihood, metode pilihan yang umum, memerlukan spesifikasi model parametrik penuh dan memberlakukan batasan praktis pada jumlah parameter yang dapat diestimasi seiring dengan $n \rightarrow \infty$. Kedua, seiring $n \rightarrow \infty$, beberapa asumsi yang tidak realistis yang diberlakukan pada exact factor models dapat dilonggarkan, dan approximate factor models dapat digunakan.

3.3 Approximate Factor Models

Seperti yang disebutkan sebelumnya, exact factor models bergantung pada asumsi yang sangat ketat bahwa tidak ada korelasi silang antara komponen idiosinkratik. Dalam dua makalah penting, Chamberlain (1983) dan Chamberlain dan Rothschild (1983) memperkenalkan approximate factor models dengan melonggarkan asumsi ini. Mereka mengizinkan komponen idiosinkratik untuk memiliki korelasi silang yang ringan dan memberikan serangkaian kondisi yang memastikan bahwa approximate factor models teridentifikasi secara asimtotik ketika $n \rightarrow \infty$.

Misalkan $x_{nt} = (x_{1t}, \dots, x_{nt})'$ adalah vektor yang berisi observasi ke- t dari n variabel pertama ketika $n \rightarrow \infty$, dan $\Sigma_n = \text{cov}(x_{nt})$ adalah matriks kovarian dari x_t . Dengan menyatakan $\lambda_1(A) \geq \lambda_2(A) \geq \dots \geq \lambda_n(A)$ sebagai eigenvalues yang terurut dari matriks simetris A dengan ukuran $(n \times n)$, asumsi-asumsi yang mendasari approximate factor models adalah sebagai berikut:

(CR1) $\sup_n \lambda_r(\Sigma_n) = \infty$ (eigenvalues terbesar r dari Σ_n divergen)

(CR2) $\sup_n \lambda_{r+1}(\Sigma_n) < \infty$ (eigenvalues yang tersisa dari Σ_n terbatas)

(CR3) $\inf_n \lambda_n(\Sigma_n) > 0$ (Σ_n tidak mendekati singularitas)

Para penulis menunjukkan bahwa di bawah asumsi (CR1)–(CR3), terdapat dekomposisi unik $\Sigma_n = \Lambda_n \Lambda_n' + \Psi_n$, di mana Λ_n adalah urutan matriks $n \times r$ dengan rank r dan $\lambda_i(\Lambda_n \Lambda_n') \rightarrow \infty$ untuk semua $i = 1, \dots, r$, dan $\lambda_1(\Psi_n) < \infty$. Sebagai alternatif, x_t dapat didekomposisi menggunakan sepasang proses vektor acak yang saling ortogonal, f_t dan e_{nt} :

$$x_{nt} = \mu_n + \Lambda_n f_t + e_{nt}, \quad (9)$$

dengan $\text{cov}(f_t) = I_r$ dan $\text{cov}(e_{nt}) = \Psi_n$, di mana r common factors tersebar secara luas dalam arti bahwa jumlah variabel yang dipengaruhi oleh setiap faktor bertambah seiring dengan n , dan komponen idiosinkratik mungkin sedikit berkorelasi dengan kovarian yang terbatas.

Meskipun awalnya dikembangkan dalam literatur keuangan (lihat juga Connor & Korajczyk, 1986, 1988, 1993), approximate static factor model masuk ke dalam makroekonometrika pada awal 2000-an (lihat misalnya Bai, 2003; Bai & Ng, 2002; Stock & Watson, 2002a, b). Makalah-makalah ini menggunakan asumsi yang analog dengan (CR1)–(CR3) untuk matriks kovarian dari factor loadings dan komponen idiosinkratik, tetapi mereka menambahkan asumsi pelengkap (yang bervariasi antar penulis karena alasan teknis) untuk mengakomodasi fakta bahwa data yang dikaji adalah time series yang berkorelasi sendiri. Model ini terutama digunakan dengan data yang stasioner atau telah diproses untuk menjadi stasioner, tetapi juga telah digunakan dalam kerangka kerja non-stasioner (lihat Bai, 2004; Bai & Ng, 2004).

Serupa dengan exact dynamic factor models, approximate dynamic factor models juga bergantung pada persamaan yang menghubungkan deret yang dapat diamati dengan factors dan lags-nya, tetapi di sini komponen idiosinkratik dapat memiliki korelasi silang yang ringan, dan jumlah deret diasumsikan cenderung tak hingga. Model ini memiliki representasi dinamis sebagai berikut:

$$x_{nt} = \mu_n + \Lambda_n(L) f_t + e_{nt}. \quad (10)$$

dan representasi statis

$$x_t^n = \mu_n + \Lambda_n F_t + e_t^n \quad (11)$$

yang setara dengan (7) dan (8), masing-masing.

Dengan memusatkan deret yang diamati, μ_n dapat diset sama dengan nol. Demi kesederhanaan, di sisa bab ini kita akan mengasumsikan bahwa variabel-variabel sudah dipusatkan, dan kita juga menghilangkan sub- dan superscript n pada Λ_n , x_t^n , dan e_t^n . Kita akan selalu mengasumsikan bahwa dalam exact factor models jumlah deret yang dipelajari terbatas, sedangkan dalam approximate factor models $n \rightarrow \infty$, dan serangkaian asumsi yang analog dengan (CR1)–(CR3)—tetapi sesuai dengan kerangka umum dari proses stasioner yang berkorelasi sendiri—terpenuhi.

3.4 Estimasi dalam Domain Waktu

3.4.1 Maximum Likelihood Estimation untuk Small Factor Models

Model faktor statis secara umum diestimasi dengan maximum likelihood di bawah asumsi bahwa $(f_t)_{t \in \mathbb{Z}}$ dan $(e_t)_{t \in \mathbb{Z}}$ adalah dua proses Gaussian iid yang ortogonal. Identifikasi unik model memerlukan

pemberlakuan beberapa pembatasan pada model. Salah satu pembatasan ini berasal dari definisi exact factor model: komponen idiosinkratik diatur sebagai proses yang ortogonal secara mutual dengan matriks varians diagonal. Pembatasan kedua menetapkan varians dari faktor menjadi matriks identitas, $\text{Var}(f_t) = I_r$. Meskipun estimator tidak memiliki solusi analitis dalam bentuk tertutup, untuk n yang kecil, jumlah parameternya kecil, dan estimasi dapat diperoleh melalui prosedur optimasi numerik.

Dua metode spesifik telah diusulkan untuk masalah ini: metode zig-zag, sebuah algoritma yang menyelesaikan syarat-syarat orde pertama (lihat, misalnya, Anderson, 1984; Lawley & Maxwell, 1971; Magnus & Neudecker, 2019), dan pendekatan Jöreskog (1967), yang bergantung pada maksimasi likelihood terkonsentrasi menggunakan algoritma Fletcher–Powell. Kedua pendekatan ini memberlakukan pembatasan identifikasi tambahan pada Λ . Estimator maximum likelihood $\hat{\Lambda}, \hat{\Sigma}$ dari parameter model Λ, Σ adalah $\sqrt{T}$ konsisten dan asimtotik Gaussian (lihat Anderson & Rubin, 1956).

Di bawah asumsi stasioneritas standar, hasil asimtotik ini tetap valid bahkan jika distribusi sebenarnya dari f_t atau e_t tidak Gaussian: dalam kasus ini, $\hat{\Lambda}$ dan $\hat{\Sigma}$ adalah estimator quasi-maximum likelihood (QML) dari Λ dan Σ .

Berbagai rumus telah diusulkan untuk mengestimasi faktor, berdasarkan estimasi parameter $\hat{\Lambda}, \hat{\Sigma}$. Rumus yang umum digunakan antara lain:

- $\hat{f}_t = \hat{\Lambda}'(\hat{\Lambda}\hat{\Lambda}' + \hat{\Sigma})^{-1}x_t$, ekspektasi kondisional dari f_t yang diberikan x_t dan nilai estimasi dari parameter, yang setelah perhitungan dasar juga dapat ditulis sebagai $\hat{f}_t = (I_r + \hat{\Lambda}'\hat{\Sigma}^{-1}\hat{\Lambda})^{-1}\hat{\Lambda}'\hat{\Sigma}^{-1}x_t$.
- $\hat{f}_t = (\hat{\Lambda}'\hat{\Sigma}^{-1}\hat{\Lambda})^{-1}\hat{\Lambda}'\hat{\Sigma}^{-1}x_t$ yang merupakan estimator FGLS dari f_t , berdasarkan estimated loadings.

Detail tambahan mengenai dua estimator ini disediakan oleh Anderson (1984). Karena rumus-rumus ini setara hingga matriks yang invertibel, ruang-ruang yang dibentangkan oleh faktor estimasi adalah identik di seluruh metode ini.

Model faktor dinamis juga dapat diestimasi dengan maximum likelihood di bawah asumsi Gaussian $(f'_t, e'_t)_{t \in \mathbb{Z}}$. Dalam hal ini, faktor diasumsikan mengikuti proses vector autoregressive, dan model dapat dirumuskan dalam bentuk state-space. Untuk lebih memperjelas, mari kita pertimbangkan model faktor di mana vektor faktor mengikuti proses VAR(p) dan masuk ke persamaan untuk x_t dengan s lags:

$$x_t = \Lambda_0 f_t + \Lambda_1 f_{t-1} + \cdots + \Lambda_s f_{t-s} + e_t, \quad (12)$$

$$f_t = \Phi_1 f_{t-1} + \cdots + \Phi_p f_{t-p} + u_t, \quad (13)$$

di mana matriks koefisien VAR(p), Φ , menangkap dinamika faktor. Pembatasan identifikasi yang umum digunakan menetapkan varians dari inovasi menjadi matriks identitas, $\text{cov}(u_t) = I_r$, dan pembatasan identifikasi tambahan diberlakukan pada factor loadings. Representasi state-space sangat fleksibel dan dapat mengakomodasi berbagai kasus seperti yang ditunjukkan di bawah ini:

- Jika $s \geq p - 1$ dan jika e_t adalah white noise, persamaan pengukuran adalah $x_t = \Lambda F_t + e_t$ dengan $\Lambda = (\Lambda_0 \Lambda_1 \dots \Lambda_s)$ dan $F_t = (f'_t f'_{t-1} \dots f'_{t-s})'$, (representasi statis dari model dinamis), dan persamaan keadaan adalah:

$$\begin{bmatrix} f_t \\ f_{t-1} \\ \vdots \\ f_{t-p+1} \\ \vdots \\ f_{t-s} \end{bmatrix} = \begin{bmatrix} \Phi_1 & \dots & \Phi_p & O & \dots & O \\ I_q & O & \dots & \dots & \dots & O \\ O & I_q & O & \dots & \dots & O \\ \vdots & \vdots & \dots & \dots & \dots & \vdots \\ O & \dots & O & I_q & O & \end{bmatrix} \begin{bmatrix} f_{t-1} \\ f_{t-2} \\ \vdots \\ f_{t-p} \\ \vdots \\ f_{t-s-1} \end{bmatrix} + \begin{bmatrix} I_q \\ O \\ \vdots \\ O \end{bmatrix} u_t$$

3.4.2 Principal Component Analysis untuk Large Approximate Factor Models

Chamberlain dan Rothschild (1983) menyarankan penggunaan principal component analysis (PCA) untuk mengestimasi approximate static factor model, dan Stock dan Watson (2002a,b) serta Bai dan Ng (2002) mempopulerkan pendekatan ini dalam makroekonometrika.

Dengan mempertimbangkan data yang dipusatkan dan mengasumsikan bahwa jumlah faktor, r , diketahui, PCA memungkinkan estimasi simultan dari faktor dan loadings mereka dengan menyelesaikan masalah least squares

$$\min_{\Lambda, F} \frac{1}{nT} \sum_{i=1}^n \sum_{t=1}^T (x_{it} - \lambda'_i f_t)^2 = \min_{\Lambda, F} \frac{1}{nT} \sum_{t=1}^T (x_t - \Lambda f_t)' (x_t - \Lambda f_t). \quad (14)$$

Karena adanya ketidakpastian rotasi dari faktor dan loadings mereka, estimasi parameter harus dibatasi untuk mendapatkan solusi yang unik. Biasanya, salah satu dari dua kondisi normalisasi berikut diberlakukan:

$$\frac{1}{T} \sum_{t=1}^T \hat{f}_t \hat{f}_t' = I_r \quad \text{atau} \quad \frac{\hat{\Lambda}' \hat{\Lambda}}{n} = I_r. \quad (15)$$

Dengan menggunakan normalisasi pertama dan mengeliminasi Λ , diperoleh matriks faktor yang diestimasi, $\hat{F}$, yang merupakan T kali eigenvectors yang sesuai dengan r eigenvalues terbesar dari matriks $T \times T$, XX' . Berdasarkan $\hat{F}$, $\hat{\Lambda} = (\hat{F}' \hat{F})^{-1} \hat{F}' X = \hat{F}' X / T$ adalah matriks factor loadings yang bersesuaian. Solusi untuk masalah minimisasi di atas tidak unik, meskipun jumlah residual kuadratnya unik. Solusi lain diberikan oleh $\tilde{\Lambda}$ yang dibentuk sebagai n kali eigenvectors yang sesuai dengan r eigenvalues terbesar dari matriks $n \times n$, $X'X$. Penggunaan normalisasi kedua di sini menyiratkan $\tilde{F} = X \tilde{\Lambda} / n$. Bai dan Ng (2002) menunjukkan bahwa pendekatan kedua ini secara komputasi lebih murah ketika $T > n$, sedangkan pendekatan pertama lebih menuntut ketika $T < n$. Dalam kedua kasus, komponen idiosinkratik diestimasi dengan:

$$\hat{e}_t = x_t - \hat{\Lambda} \hat{f}_t, \quad (16)$$

dan kovariansi mereka diestimasi dengan matriks kovariansi empiris dari $\hat{e}_t$. Karena PCA tidak invariant terhadap skala, banyak penulis (misalnya Stock & Watson, 2002a,b) memusatkan dan menstandarkan deret, yang umumnya diukur dalam satuan yang berbeda, dan sebagai hasilnya, PCA diterapkan pada matriks korelasi sampel dalam kasus ini.

Stock dan Watson (2002a,b) dan Bai dan Ng (2002) membuktikan konsistensi dari estimator-

estimator ini, dan Bai (2003) memperoleh distribusi asimtotiknya di bawah serangkaian asumsi yang lebih kuat. Kami merujuk pembaca ke makalah-makalah tersebut untuk detail lebih lanjut, namun kami mencatat bahwa para penulis ini menggantikan asumsi (CR1) dengan asumsi yang lebih kuat sebagai berikut:

$$\lim_{n \rightarrow \infty} \frac{\Lambda' \Lambda}{n} = \Phi, \quad (17)$$

dan menggantikan asumsi (CR2) dan (CR3), yang dirancang untuk data white noise, dengan asumsi-asumsi yang analog dengan memperhitungkan autokorelasi pada faktor dan komponen idiosinkratik. Di bawah asumsi-asumsi ini, faktor dan loadings terbukti konsisten, hingga sebuah matriks invertibel H , konvergen pada tingkat $\delta_{nT} = \frac{1}{\min(\sqrt{n}, \sqrt{T})} I_r$, sehingga:

$$\hat{f}_t - H f_t = O_P(\delta_{nT}) \quad \text{dan} \quad \hat{\lambda}_i - H^{-1} \lambda_i = O_P(\delta_{nT}), \quad \forall i = 1, \dots, n. \quad (18)$$

Asumsi yang lebih lemah juga dapat digunakan:

$$0 < c \leq \liminf_{n \rightarrow \infty} \lambda_r(\Lambda' \Lambda / n) < \limsup_{n \rightarrow \infty} \lambda_1(\Lambda' \Lambda / n) \leq C < \infty \quad (19)$$

(lihat Doz, Giannone, & Reichlin, 2011).

Di bawah serangkaian asumsi yang lebih ketat, Bai (2003) juga memperoleh hasil distribusi asimtotik berikut:

- Jika $\sqrt{n}/T \rightarrow 0$, maka, untuk setiap t :

$$\sqrt{n}(\hat{f}_t - H' f_t) \xrightarrow{d} N(0, \Phi_t) \quad \text{di mana } \Phi_t \text{ diketahui.}$$

- Jika $\sqrt{T}/n \rightarrow 0$, maka, untuk setiap i :

$$\sqrt{T}(\hat{\lambda}_i - H^{-1} \lambda_i) \xrightarrow{d} N(0, W_i) \quad \text{di mana } W_i \text{ diketahui.}$$

3.4.3 Generalized Principal Component Analysis untuk Large Approximate Factor Models

Estimasi generalized principal components meniru generalized least squares untuk menangani matriks varians non-spherical dari komponen idiosinkratik. Meskipun metode ini telah digunakan sebelumnya, Choi (2012) adalah orang yang membuktikan bahwa peningkatan efisiensi dapat dicapai dengan memasukkan matriks pembobotan dalam minimisasi:

$$\min_{\Lambda, F} \frac{1}{nT} \sum_{t=1}^T (x_t - \Lambda f_t)' \hat{\Sigma}^{-1} (x_t - \Lambda f_t). \quad (20)$$

Estimator generalized principal component yang dapat dilakukan menggantikan Σ yang tidak diketahui dengan estimator $\hat{\Sigma}$. Elemen diagonal dari Σ dapat diestimasi melalui varians dari masing-masing komponen idiosinkratik (lihat Boivin & Ng, 2006; Jones, 2001). Bai dan Liao (2013) merumuskan kondisi-kondisi di mana $\hat{\Sigma}$ yang diestimasi dapat diperlakukan sebagai diketahui.

Masalah minimisasi berbobot di atas bergantung pada asumsi bahwa kejutan idiosinkratik bersifat independen, yang mungkin terlalu restriktif dalam praktik. Stock dan Watson (2005) menerapkan filter diagonal $D(L)$ pada komponen idiosinkratik untuk menangani autokorelasi serial, sehingga masalahnya menjadi:

$$\min_{D(L), \Lambda, \tilde{F}} \frac{1}{T} \sum_{t=1}^T (D(L)x_t - \Lambda \tilde{f}_t)' \tilde{\Sigma}^{-1} (D(L)x_t - \Lambda \tilde{f}_t), \quad (21)$$

di mana $\tilde{F} = (\tilde{f}_1, \dots, \tilde{f}_T)'$ dengan $\tilde{f}_t = D(L)f_t$ dan $\tilde{\Sigma} = E[\tilde{e}_t \tilde{e}_t']$ dengan $\tilde{e}_t = D(L)e_t$.

Estimasi $D(L)$ dan $\tilde{F}$ dapat dilakukan secara berurutan, berulang hingga konvergen. Breitung dan Tenhofen (2011) mengusulkan prosedur estimasi dua langkah yang serupa yang memungkinkan adanya heteroskedastisitas dan autokorelasi serial dalam komponen idiosinkratik.

Meskipun PCA pertama kali digunakan untuk mengestimasi approximate factor models di mana faktor dan komponen idiosinkratiknya adalah white noise iid, sebagian besar hasil asimtotik tetap berlaku ketika faktor dan komponen idiosinkratik adalah proses stasioner yang berkorelasi secara otomatis. Akibatnya, metode ini telah banyak digunakan sebagai dasar dalam estimasi approximate dynamic factor model, tetapi diperlukan beberapa perluasan karena PCA sendiri tidak menangkap dinamika.

3.4.4 Two-Step dan Quasi-Maximum Likelihood Estimation untuk Large Approximate Factor Models

Doz et al. (2011) mengusulkan estimator two-step yang mempertimbangkan dinamika faktor. Mereka mengasumsikan bahwa faktor dalam approximate dynamic factor model $x_t = \Lambda f_t + e_t$ mengikuti proses vector autoregressive, $f_t = \Phi_1 f_{t-1} + \dots + \Phi_p f_{t-p} + u_t$, dan mereka mengizinkan komponen idiosinkratik untuk memiliki autokorelasi tetapi tidak menentukan dinamika mereka. Prosedur estimasi adalah sebagai berikut:

- **Langkah 1:** Estimator awal dari loadings, $\hat{\Lambda}$, dan faktor, $\hat{f}_t$, diperoleh melalui principal component analysis. Komponen idiosinkratik diestimasi dengan $\hat{e}_{it} = x_{it} - \hat{\Lambda}'_i \hat{f}_t$, dan variansnya diestimasi melalui varians empiris terkait $\hat{\psi}_{ii}$. Faktor yang diestimasi, $\hat{f}_t$, digunakan dalam model vector-autoregressive untuk mendapatkan estimasi $\hat{\Phi}_j$, $j = 1, \dots, p$.
- **Langkah 2:** Model dirumuskan dalam bentuk state-space seperti pada (2.7), dengan varians dari common shocks diatur sebagai matriks identitas, $\text{cov}(u_t) = I_r$, dan $\text{cov}(e_t)$ didefinisikan sebagai $\Sigma = \text{diag}(\psi_{11}, \dots, \psi_{nn})$. Menggunakan estimasi parameter $\hat{\Lambda}$, $\hat{\Sigma}$, $\hat{\Phi}_j$, $j = 1, \dots, p$, yang diperoleh pada langkah pertama, satu kali penerapan Kalman smoother kemudian dilakukan pada data. Ini menghasilkan estimasi baru dari faktor, $\hat{f}_t|T = E(f_t|x_1, \dots, x_T, \hat{\theta})$, di mana $\hat{\theta}$ adalah vektor yang berisi estimasi pertama dari semua parameter. Penting untuk dicatat bahwa, dalam langkah kedua ini, komponen idiosinkratik tidak ditentukan dengan benar, karena mereka diasumsikan sebagai white noises yang ortogonal satu sama lain.

Doz et al. (2011) membuktikan bahwa, di bawah asumsi mereka, estimasi parameter, $\hat{\theta}$, konsisten, berkumpul dengan laju $(\min(\sqrt{n}, \sqrt{T}))^{-1}$. Mereka juga membuktikan bahwa, ketika Kalman

smoother dijalankan dengan estimasi parameter tersebut alih-alih parameter sebenarnya, estimator two-step dari f_t yang dihasilkan juga konsisten dengan $\min(\sqrt{n}, \sqrt{T})$.

Doz, Giannone, dan Reichlin (2012) mengusulkan untuk mengestimasi large scale approximate dynamic factor model menggunakan quasi-maximum likelihood (QML). Sejalan dengan Doz et al. (2011), quasi-likelihood didasarkan pada asumsi bahwa komponen idiosinkratik adalah iid Gaussian yang ortogonal satu sama lain (sehingga model diperlakukan seolah-olah itu adalah exact factor model, meskipun bukan), dan model VAR Gaussian untuk faktor. Log-likelihood yang bersesuaian dapat diperoleh dari Kalman filter untuk nilai parameter yang diberikan, dan mereka menggunakan algoritma EM untuk menghitung estimator maximum likelihood. Algoritma EM, yang diusulkan oleh Dempster, Laird, dan Rubin (1977) dan pertama kali diterapkan pada dynamic factor models oleh Watson dan Engle (1983), bergantian antara langkah ekspektasi yang bergantung pada satu pass Kalman smoother untuk nilai parameter saat ini dan langkah maksimasi yang bergantung pada regresi multivariat.

Penerapan algoritma ini sama dengan penerapan berturut-turut dari pendekatan two-step. Perhitungan dapat dilakukan bahkan ketika n besar, karena dalam setiap iterasi algoritma, estimasi saat ini dari loading ke- i , λ_i , diperoleh melalui regresi least squares biasa dari x_{it} terhadap estimasi faktor saat ini. Penulis membuktikan bahwa, di bawah serangkaian asumsi standar, faktor yang diestimasi adalah mean square consistent. Hasil mereka tetap valid meskipun proses tersebut tidak Gaussian, atau jika komponen idiosinkratik tidak iid, atau tidak ortogonal satu sama lain, selama mereka hanya lemah berkorelasi silang. Reis dan Watson (2010) menerapkan pendekatan ini pada model dengan komponen idiosinkratik yang berkorelasi serial. Jungbacker dan Koopman (2014) juga menggunakan algoritma EM untuk mengestimasi dynamic factor model dengan komponen idiosinkratik yang memiliki autokorelasi, tetapi alih-alih memperluas vektor keadaan seperti pada Eq. (2.8), mereka mentransformasikan persamaan pengukuran seperti yang dijelaskan di Bab 2.3.5.

Bai dan Li (2012) mempelajari estimasi QML dalam kasus yang lebih terbatas di mana quasi-likelihood diasosiasikan dengan static exact factor model. Mereka memperoleh konsistensi dan normalitas asimtotik dari loadings dan faktor yang diestimasi di bawah serangkaian asumsi yang tepat. Bai dan Li (2016) mengintegrasikan estimator ini ke dalam pendekatan two-step yang diajukan oleh Doz et al. (2011) dan memperoleh hasil asimtotik yang serupa. Mereka juga mengikuti Jungbacker dan Koopman (2014) untuk menangani kasus di mana komponen idiosinkratik adalah proses autoregressive. Bai dan Liao (2016) memperluas pendekatan Bai dan Li (2012) ke dalam kasus di mana matriks kovariansi idiosinkratik jarang, alih-alih diagonal, dan mengusulkan estimator penalized maximum likelihood.

3.4.5 Estimasi Large Approximate Factor Models dengan Data yang Hilang

Observasi mungkin hilang dari dataset yang dianalisis karena beberapa alasan. Pada awal sampel, beberapa deret waktu mungkin tersedia dari tanggal mulai yang lebih awal dibandingkan dengan yang lain. Pada akhir sampel, tanggal observasi terakhir dapat berbeda tergantung pada jeda rilis masing-masing deret data. Terakhir, observasi mungkin hilang di dalam sampel karena berbagai deret dalam dataset mungkin diambil sampelnya pada frekuensi yang berbeda, misalnya bulanan dan kuartalan. Teknik estimasi DFM mengasumsikan bahwa observasi hilang secara acak, sehingga tidak ada seleksi sampel yang endogen. Data yang hilang ditangani secara berbeda dalam aplikasi principal components

dan state-space.

Estimator least squares dari principal components dalam panel yang seimbang seperti yang diberikan dalam Persamaan (14) perlu dimodifikasi ketika beberapa dari nT observasi hilang. Stock dan Watson (2002b) menunjukkan bahwa estimasi F dan Λ dapat diperoleh dalam kasus ini.

4 Eksplorasi Data

Penelitian ini memfokuskan data eksplorasi dan analisis dengan berbasis pada data yang tersedia di Sistem Pemantauan Pasar dan Kebutuhan Pokok Kementerian (SP2KP) Kementerian Perdagangan Republik Indonesia (tersedia di <https://sp2kp.kemendag.go.id/>). Penelitian ini juga difokuskan pada cakupan data dari Januari 2018 hingga data tersedia terakhir, yaitu September 2024. Dasar data yang digunakan adalah data harian di level Kabupaten/Kota untuk tiga komoditas, yaitu: 1) tepung terigu; 2) minyak goreng curah kemasan curah; dan 3) minyak goreng sawit kemasan premium. Pemilihan ketiga produk tersebut dilakukan, karena setelah peneliti mengecek secara seksama, ketiga produk tersebut yang dapat mencakup keseluruhan periode dan mencerminkan pergerakan harga dua produk target utama yaitu tepung terigu dan minyak goreng.

Peneliti kemudian menghitung nilai mean, median, standar deviasi, dan koefisien disparitas harga. Dari perhitungan tersebut, kemudian diperoleh nilai di level provinsi dan frekuensi data di tingkat bulanan. Peneliti memulai analisis dengan melakukan penyesuaian dan proses sorting data dari dataset awal yang diperoleh. Peneliti melakukan penyesuaian terlebih dahulu dikarenakan adanya perubahan kategori dalam dataset tersebut. Proses ini dilakukan khusus untuk data minyak goreng curah kemasan curah dan minyak goreng sawit kemasan premium, karena data tepung terigu konsisten dalam pengkategorisasian dari Januari 2018 hingga Oktober 2023.

Peneliti menggabungkan dua kategori data untuk kedua kategori minyak goreng. Data minyak goreng curah kemasan curah merupakan penggabungan dari data komoditas minyak goreng curah kemasan curah dan minyak goreng sawit curah. Sedangkan untuk data minyak goreng sawit kemasan premium merupakan penggabungan data dengan kategori minyak goreng sawit kemasan premium dan minyak goreng sawit kemasan premium. Proses penggabungan dan penyesuaian tersebut, maka kajian dapat menggunakan keseluruhan periode analisis dan tergabung menjadi data panel yang mencakup runtun waktu kajian untuk keseluruhan 34 provinsi di Indonesia. Dari kedua subset tersebut, peneliti melakukan eksplorasi data dengan melihat profil data. Proses dilakukan dengan mengkaji nilai deskriptif statistik secara keseluruhan panel dan nilai untuk between-group dan within-group. Analisis deskriptif mencakup nilai rata-rata, median, standar deviasi, minimum, dan maksimum. Dari tahap ini, peneliti mendapatkan gambaran dari karakteristik data untuk masing-masing komoditas dalam kajian.

4.1 Perhitungan Nilai Disparitas

Untuk mendapatkan nilai disparitas harga, peneliti menggunakan indeks Theil untuk data level Kabupaten/Kota dan memperoleh nilai skalar di level provinsi di setiap bulannya. Indeks Theil digunakan untuk memperhitungkan distribusi nilai harga antar Kabupaten/Kota, sehingga dapat menangkap koefisien disparitas di sebuah provinsi. Jika diperoleh nilai mendekati 0, maka di provinsi tersebut dis-

tribusi sepenuhnya merata dengan setiap sub-wilayah memiliki nilai yang hampir sama. Sedangkan, jika nilai antar sub-wilayah sangat berbeda atau memiliki disparitas tinggi, maka indeks Theil yang dihasilkan menunjukkan nilai yang tinggi (Darity & Deshpande, 2000; Conceição et al., 2001, Xu et al, 2004). Proses pengukuran indeks Theil dalam kajian ini adalah sebagai berikut:

$$T = \frac{1}{N} \sum_{i=1}^N \frac{x_i}{\mu} \ln \left(\frac{x_i}{\mu} \right) \quad (22)$$

dengan N merupakan jumlah unit spasial untuk sub-wilayah, x_i adalah nilai harga untuk sub-wilayah i , dan μ merupakan rata-rata nilai dari keseluruhan harga di tingkat sub-wilayah Kabupaten/Kota. Pendekatan indeks Theil ini merupakan fungsi umum dari pendekatan lain, seperti koefisien variasi (CV) dalam kerangka umum fungsi entropy Theil. Peneliti memilih indeks Theil sebagai pembandingan dengan CV, yang menghitungnya lebih sederhana yang hanya berdasarkan rasio standar deviasi dibagi dengan rata-rata dari harga komoditas, σ/μ .

4.2 Koefisien Autokorelasi Spasial Secara Lokal

Peneliti juga menghitung nilai autokorelasi spasial secara lokal untuk mendapatkan komponen koefisien antar wilayah. Seperti yang telah diperoleh pada proses forum group discussion (FGD) dengan tim bidang kajian perdagangan di Kementerian Perdagangan, salah satu faktor dalam menganalisis tingkat harga di level nasional adalah dengan menggunakan nilai koefisien antar wilayah. Oleh karenanya, peneliti menawarkan metodologi untuk mengukur derajat kesamaan atau keteraturan tingkat harga di provinsi-provinsi yang berdekatan secara geografis (LeSage & Pace, 2010; Elhorst, 2014). Untuk mendapatkan nilai koefisien yang terperinci di masing-masing provinsi, peneliti menggunakan nilai autokorelasi spasial secara lokal dengan menggunakan indeks lokal Moran's I sebagai berikut:

$$I_i = \frac{(x_i - \bar{x}) \sum_{j=1}^N w_{ij} (x_j - \bar{x})}{\left(\frac{\sum_{i=1}^N (x_i - \bar{x})^2}{N} \right)}, \quad i \neq j \quad (23)$$

dengan $(x_i - \bar{x})$ merupakan disparitas atau selisih harga masing-masing provinsi terhadap rerata nasional, sedangkan $(x_j - \bar{x})$ merupakan selisih harga provinsi-provinsi yang bertetangga. Nilai w_{ij} menggambarkan tingkat keeratan (atau bobot hubungan) antara masing-masing provinsi i dengan tetangga provinsi j . Nilai tersebut berkisar antara -1 hingga 1. Jika mendekati +1 maka menunjukkan autokorelasi spasial positif, yang berarti provinsi yang berdekatan memiliki nilai yang serupa. Sedangkan jika nilai Moran tersebut mendekati -1, maka menunjukkan autokorelasi spasial negatif, yang berarti provinsi yang berdekatan memiliki nilai yang berbeda. Jika nilai I_i mendekati 0, maka tidak terlihat pola hubungan yang jelas antar provinsi yang berdekatan.

4.3 Analisis Eksplorasi Data

Peneliti melakukan eksplorasi untuk tiga komponen yang bisa diperoleh dari ekstraksi dan penyesuaian data harian komoditas menjadi: 1) rerata harga bulanan; 2) median harga bulanan; dan 3) indeks Theil harga bulanan dan koefisien variasi.

4.3.1 Minyak Goreng Curah Kemasan Curah

Tabel 1 menyajikan statistik deskriptif data panel untuk komoditas minyak goreng curah kemasan curah, dengan pembagian berdasarkan tiga kategori: Overall, Between, dan Within. Tabel ini mengukur berbagai aspek dari harga rata-rata, median harga, indeks Theil, dan koefisien variasi (CV).

Table 1: Statistik Deskriptif Data Panel Komoditas Minyak Goreng Curah Kemasan Curah

	Mean	SD	Min	Max
Rerata Harga				
Overall	13518.80	2762.77	0	27825
Between	13560.92	1164.25	12219.28	17067.72
Within	13087.08	2373.78	9893.61	19382.01
Median Harga				
Overall	13435.01	2736.41	0	30000
Between	13472.00	1137.17	12094.91	16943.85
Within	13042.37	2390.04	9786.12	19383.62
Indeks Theil				
Overall	0.0034	0.0103	0	0.3135
Between	0.0033	0.0017	0.0004	0.0071
Within	0.0030	0.0076	0	0.0580
Coefficient of Variations (CV)				
Overall	0.0657	0.0789	0	1.4142
Between	0.0666	0.0244	0.0195	0.1534
Within	0.0666	0.0682	0	0.3928

Secara umum, rata-rata harga keseluruhan minyak goreng curah adalah Rp 13.518,80 dengan standar deviasi (SD) sebesar Rp 2.762,77. Rentang harga berkisar dari Rp 0 hingga Rp 27.825. Pada level Between, yang mengukur variasi antar kabupaten/kota, rata-rata adalah Rp 13.560,92 dengan SD yang lebih rendah (Rp 1.164,25), menunjukkan perbedaan antar wilayah lebih kecil dibandingkan fluktuasi di dalam masing-masing wilayah (dengan SD sebesar Rp 2.373,78 pada level Within).

Median harga menunjukkan pola yang serupa dengan rata-rata harga. Median keseluruhan adalah Rp 13.435,01, dan nilai Between serta Within juga mengindikasikan variasi antar wilayah yang lebih kecil dibandingkan variasi dalam wilayah. Hal ini mengindikasikan adanya perbedaan harga yang teratur di antara kabupaten/kota, namun masih terjadi fluktuasi yang cukup besar dalam periode waktu yang dianalisis di dalam masing-masing wilayah.

Indeks Theil, yang digunakan untuk mengukur disparitas harga antar wilayah, menunjukkan nilai keseluruhan yang relatif rendah (0,0034), mengindikasikan bahwa perbedaan harga antar wilayah tidak terlalu besar secara keseluruhan. Pada level Between, indeks Theil lebih stabil dengan SD yang rendah, mengindikasikan bahwa disparitas antar kabupaten/kota dalam provinsi lebih kecil dibandingkan disparitas dalam provinsi itu sendiri (nilai Within).

Akhirnya, koefisien variasi (CV), yang mengukur variabilitas relatif harga, menunjukkan nilai overall sebesar 0,0657 dengan fluktuasi yang signifikan (maksimal 1,4142). Pada level Between, nilai CV lebih kecil (0,0666) dibandingkan dengan fluktuasi dalam wilayah (Within) yang memiliki variabilitas relatif lebih besar (SD 0,0682). Hal ini menunjukkan bahwa variasi harga lebih tinggi di dalam

kabupaten/kota, sementara perbedaan antar kabupaten/kota dalam satu provinsi lebih kecil.

Secara keseluruhan, tabel ini memberikan gambaran yang komprehensif mengenai distribusi harga minyak goreng curah di berbagai wilayah, memperlihatkan adanya variasi harga yang lebih besar dalam suatu wilayah dibandingkan antar wilayah.

Tabel x.x dalam Appendix Minyak Goreng menunjukkan Local Moran's I untuk harga minyak goreng curah kemasan curah di berbagai provinsi di Indonesia dari tahun 2018 hingga 2023. Local Moran's I adalah ukuran statistik yang menunjukkan autokorelasi spasial dari suatu variabel, dalam hal ini harga minyak goreng curah, di suatu wilayah dengan mempertimbangkan keterkaitan antar-wilayah atau provinsi yang bertetangga. Nilai yang mendekati +1 menunjukkan adanya autokorelasi spasial positif, yang berarti provinsi yang berdekatan cenderung memiliki harga yang mirip. Sebaliknya, nilai yang mendekati -1 menunjukkan autokorelasi spasial negatif, di mana provinsi yang bertetangga cenderung memiliki perbedaan harga yang signifikan. Jika Local Moran's I mendekati 0, ini menunjukkan bahwa tidak ada pola keterkaitan spasial yang jelas.

Secara umum, beberapa provinsi seperti Aceh, Banten, dan Jawa Tengah menunjukkan Local Moran's I yang positif dan konsisten di atas 0, terutama pada tahun 2022 dan 2023, menunjukkan bahwa harga minyak goreng curah di provinsi-provinsi ini cenderung memiliki keterkaitan positif dengan wilayah sekitarnya. Ini mengindikasikan bahwa distribusi harga minyak goreng antar provinsi yang bertetangga di wilayah tersebut cenderung seragam, terutama dalam dua tahun terakhir.

Sebaliknya, provinsi seperti Kalimantan Utara dan Maluku menunjukkan nilai Local Moran's I yang negatif, terutama pada tahun 2020 dan 2021. Hal ini menunjukkan adanya ketidaksesuaian harga antar provinsi di wilayah tersebut, di mana harga minyak goreng di Kalimantan Utara dan Maluku cenderung berbeda secara signifikan dari provinsi-provinsi tetangga.

Ada juga fluktuasi yang mencolok di beberapa provinsi. Sebagai contoh, Papua Barat menunjukkan nilai yang sangat tinggi pada tahun 2023 dengan Local Moran's I mencapai 0.6253, meningkat signifikan dari tahun-tahun sebelumnya, yang mungkin mengindikasikan adanya peningkatan keseragaman harga minyak goreng curah di wilayah Papua dan provinsi-provinsi sekitarnya.

Perubahan signifikan pada Local Moran's I dari tahun ke tahun dapat mengindikasikan adanya intervensi kebijakan atau perubahan dinamika pasar yang mempengaruhi distribusi harga antar wilayah. Misalnya, beberapa provinsi seperti Sumatera Utara menunjukkan peningkatan korelasi spasial dari 0.1034 pada 2019 menjadi 0.2502 pada 2023, yang menunjukkan adanya peningkatan homogenitas harga minyak goreng di wilayah tersebut.

Tabel ini mengindikasikan bahwa ada variasi dalam keterkaitan spasial harga minyak goreng curah antar provinsi di Indonesia. Perubahan dari waktu ke waktu dan antar provinsi ini bisa menjadi indikasi adanya ketidakstabilan harga atau perbedaan struktur pasar yang signifikan antar wilayah.

4.3.2 Minyak Goreng Sawit Kemasan Premium

Tabel 2 menampilkan statistik deskriptif dari data panel komoditas minyak goreng sawit kemasan premium, yang diukur melalui berbagai dimensi seperti harga rata-rata, median harga, indeks Theil, dan koefisien variasi (CV). Statistik ini disajikan dalam tiga tingkatan: overall, between, dan within. Dimensi "overall" menunjukkan statistik agregat dari seluruh data, sementara "between" menggambarkan variasi antarunit (dalam hal ini antar wilayah), dan "within" menunjukkan variasi dalam unit

yang sama selama periode waktu yang diteliti.

Table 2: Statistik Deskriptif Data Panel Komoditas Minyak Goreng Sawit Kemasan Premium

	Mean	SD	Min	Max
Rerata Harga				
Overall	17,452.58	4,083.07	11,555.33	69,143.76
Between	17,455.43	1,306.89	15,471.94	20,653.58
Within	17,444.81	3,671.39	13,934.08	27,659.18
Median Harga				
Overall	17,403.72	3,902.07	11,000.00	40,000.00
Between	17,406.80	1,315.74	15,423.26	20,147.86
Within	17,420.45	3,614.89	13,808.57	27,200.00
Indeks Theil				
Overall	0.0050	0.0992	0	4.8793
Between	0.0049	0.0118	0.0009	0.0712
Within	0.0054	0.0273	0	0.2216
Coefficient of Variations (CV)				
Overall	0.0668	0.4624	0	22.4825
Between	0.0666	0.0593	0.0232	0.3934
Within	0.0562	0.0618	0.0003	0.3954

Berdasarkan rata-rata harga (Overall Mean), harga minyak goreng sawit kemasan premium mencapai Rp 17.452,58, dengan standar deviasi Rp 4.083,07, yang mencerminkan variasi harga yang cukup besar. Nilai minimum dari keseluruhan data adalah Rp 11.555,33 dan nilai maksimumnya mencapai Rp 69.143,76, yang menunjukkan adanya perbedaan harga yang sangat signifikan di beberapa wilayah atau periode waktu. Di tingkat "between", variasi antar wilayah lebih kecil, dengan harga rata-rata berkisar antara Rp 15.471,94 hingga Rp 20.653,58. Ini menandakan bahwa ada perbedaan harga antar wilayah, namun lebih terkontrol dibandingkan variasi keseluruhan. Sementara itu, pada dimensi "within," rata-rata per wilayah dan waktu menunjukkan kisaran harga yang bervariasi dari Rp 13.934,08 hingga Rp 27.659,18, mengindikasikan adanya fluktuasi harga dalam wilayah yang sama seiring waktu.

Median harga menunjukkan tren yang mirip dengan rata-rata, yang mendukung distribusi harga yang serupa antara wilayah dan waktu. Nilai minimum dan maksimum pada median harga juga menunjukkan variasi yang signifikan, dengan rentang harga Rp 11.000,00 hingga Rp 40.000,00.

Indeks Theil digunakan untuk mengukur disparitas harga antar wilayah. Nilai indeks Theil keseluruhan yang rendah (0.0050) menunjukkan bahwa secara umum distribusi harga cenderung merata di berbagai wilayah, meskipun terdapat beberapa wilayah yang memiliki disparitas harga lebih tinggi dengan nilai maksimum mencapai 4.8793. Pada tingkat "between," disparitas antar wilayah juga tetap rendah, dengan indeks Theil berkisar antara 0.0009 hingga 0.0712. Sementara itu, pada tingkat "within," fluktuasi harga dalam wilayah tertentu lebih besar, yang ditunjukkan oleh nilai maksimum 0.2216.

Koefisien variasi (CV) mengukur tingkat variasi relatif dari harga. Nilai CV keseluruhan sebesar 0.0668 menunjukkan bahwa variasi harga relatif kecil dibandingkan dengan harga rata-rata, meskipun

ada wilayah atau periode tertentu yang mengalami variasi harga yang ekstrem, dengan nilai maksimum CV mencapai 22.4825. Pada dimensi "between," variasi antar wilayah lebih terkendali, dengan nilai maksimum 0.3934. Sedangkan pada dimensi "within," nilai CV juga relatif lebih kecil namun menunjukkan adanya fluktuasi harga dalam wilayah tertentu, dengan nilai maksimum 0.3954.

Secara keseluruhan, tabel ini memberikan wawasan penting mengenai variasi harga minyak goreng sawit kemasan premium, baik antar wilayah maupun antar waktu. Analisis ini menunjukkan adanya perbedaan harga antar wilayah dan fluktuasi harga dalam wilayah tertentu seiring waktu, meskipun secara umum harga cenderung merata dengan disparitas yang rendah di sebagian besar wilayah. Namun, adanya fluktuasi harga yang lebih tinggi dalam beberapa wilayah menunjukkan adanya ketidakstabilan harga di tingkat lokal, yang mungkin dipengaruhi oleh faktor-faktor spesifik seperti kebijakan daerah, logistik, atau perubahan permintaan dan penawaran di wilayah tersebut.

Tabel x.x di dalam Appendix Local Moran Minyak Goreng menunjukkan hasil analisis Local Moran's I untuk rerata harga minyak goreng sawit kemasan premium di berbagai provinsi di Indonesia antara tahun 2018 hingga 2023. Nilai Local Moran's I digunakan untuk mengukur autokorelasi spasial lokal, yaitu seberapa besar kesamaan atau perbedaan harga antar provinsi yang berdekatan. Nilai positif menunjukkan adanya autokorelasi spasial positif, di mana provinsi yang berdekatan cenderung memiliki harga yang serupa, sedangkan nilai negatif menunjukkan autokorelasi spasial negatif, di mana provinsi yang berdekatan memiliki harga yang berbeda.

Sebagai contoh, provinsi Aceh secara konsisten memiliki nilai negatif kecil, yang menunjukkan bahwa harga minyak goreng sawit di Aceh relatif berbeda dibandingkan dengan provinsi tetangganya. Bali menunjukkan pergeseran signifikan dari nilai negatif di tahun-tahun awal menuju nilai positif yang lebih tinggi pada 2022 dan 2023, mengindikasikan peningkatan keserupaan harga dengan provinsi-provinsi tetangganya pada tahun-tahun terakhir.

Provinsi seperti Banten dan Jakarta cenderung menunjukkan nilai positif yang tinggi dan stabil, terutama di tahun-tahun awal, yang mengindikasikan bahwa harga di wilayah ini sangat berkorelasi dengan provinsi-provinsi tetangganya. Provinsi lain seperti Jawa Tengah dan Jawa Barat juga menunjukkan nilai Local Moran's I yang positif konsisten, mengindikasikan bahwa harga di wilayah-wilayah tersebut relatif serupa dengan provinsi sekitarnya.

Sebaliknya, beberapa provinsi seperti Kalimantan Barat dan Kalimantan Tengah cenderung memiliki nilai Local Moran's I yang negatif atau mendekati nol, yang berarti harga di wilayah ini cenderung berbeda atau tidak memiliki pola hubungan yang jelas dengan provinsi tetangganya.

Yang menarik, provinsi-provinsi di bagian timur Indonesia, seperti Papua dan Papua Barat, menunjukkan nilai autokorelasi yang sangat tinggi, terutama pada 2023, yang menunjukkan bahwa harga di provinsi-provinsi ini semakin terhubung satu sama lain dan mengikuti pola yang serupa dengan wilayah di sekitarnya.

Peneliti dapat melihat adanya variasi dalam hubungan harga minyak goreng sawit antar provinsi di Indonesia. Provinsi-provinsi di Pulau Jawa cenderung memiliki autokorelasi spasial positif yang kuat, sementara provinsi di Kalimantan dan bagian timur Indonesia menunjukkan variasi yang lebih besar, dengan beberapa wilayah menunjukkan nilai yang tinggi dan lainnya cenderung negatif atau mendekati nol. Penurunan dan kenaikan nilai dari waktu ke waktu juga memberikan indikasi adanya dinamika harga regional yang berubah seiring dengan perkembangan pasar dan kebijakan di setiap

provinsi.

4.3.3 Tepung Terigu

Tabel 3 menyajikan statistik deskriptif untuk komoditas tepung terigu berdasarkan data panel. Statistik ini meliputi rerata harga, median harga, indeks Theil, dan koefisien variasi (CV). Data dibagi menjadi tiga dimensi: overall, between, dan within, yang memberikan wawasan mengenai variasi antarwilayah (between) dan variasi dalam wilayah yang sama dari waktu ke waktu (within).

Table 3: Statistik Deskriptif Data Panel Komoditas Tepung Terigu

	Mean	SD	Min	Max
Rerata Harga				
Overall	10,990.71	1,996.07	7,000.00	20,869.49
Between	10,990.36	915.81	9,552.84	13,093.08
Within	11,033.54	1,711.56	8,574.97	13,923.30
Median Harga				
Overall	11,004.87	1,985.05	7,000.00	16,500.00
Between	11,004.35	885.64	9,355.74	12,833.33
Within	11,064.66	1,716.64	8,542.06	13,896.67
Indeks Theil				
Overall	0.0055	0.0174	0	0.4086
Between	0.0055	0.0035	0.0006	0.0163
Within	0.0058	0.0128	0.0001	0.1004
Coefficient of Variations (CV)				
Overall	0.0845	0.0909	0	1.4090
Between	0.0842	0.0336	0.0207	0.1613
Within	0.1023	0.0743	0.0097	0.5196

Rerata harga tepung terigu secara keseluruhan (overall) berada pada angka Rp 10.990,71 dengan standar deviasi Rp 1.996,07, yang menunjukkan adanya variasi yang cukup besar dalam harga di berbagai wilayah. Nilai minimum dan maksimum berkisar dari Rp 7.000 hingga Rp 20.869,49. Pada tingkat between (antarwilayah), rerata harga bervariasi lebih rendah dengan standar deviasi yang lebih kecil, yaitu Rp 915,81, yang menunjukkan bahwa antarwilayah tidak memiliki variasi yang terlalu besar. Namun, pada dimensi within (dalam satu wilayah dari waktu ke waktu), standar deviasi sedikit lebih tinggi yaitu Rp 1.711,56, menunjukkan adanya fluktuasi harga dalam wilayah tertentu dari waktu ke waktu.

Median harga menunjukkan pola yang mirip dengan rerata, di mana nilai overall sebesar Rp 11.004,87 dengan standar deviasi Rp 1.985,05. Nilai minimum dan maksimum berkisar dari Rp 7.000 hingga Rp 16.500. Pola variasi yang lebih kecil juga terlihat pada dimensi between, sedangkan fluktuasi yang lebih besar terlihat pada dimensi within.

Indeks Theil, yang mengukur disparitas harga antarwilayah, menunjukkan nilai overall sebesar 0,0055 dengan standar deviasi 0,0174, yang menandakan adanya kesenjangan yang cukup rendah dalam distribusi harga antarwilayah. Nilai between menunjukkan disparitas antarwilayah yang sedikit lebih kecil dengan standar deviasi 0,0035, sementara nilai within menunjukkan adanya fluktuasi harga dalam

wilayah yang lebih signifikan dengan standar deviasi 0,0128.

Koefisien variasi (CV) memberikan informasi tentang tingkat variabilitas relatif harga terhadap rerata. Secara keseluruhan, CV sebesar 0,0845 menunjukkan variabilitas yang moderat. Namun, pada dimensi within, variabilitas meningkat menjadi 0,1023, mengindikasikan bahwa variasi harga dalam satu wilayah dari waktu ke waktu lebih besar dibandingkan variasi antarwilayah.

Secara keseluruhan, tabel ini menggambarkan bahwa walaupun terdapat variasi harga antarwilayah, fluktuasi harga yang lebih besar terjadi di dalam wilayah itu sendiri dari waktu ke waktu. Hal ini menunjukkan pentingnya pemantauan harga di tingkat wilayah serta kebutuhan untuk memahami faktor-faktor lokal yang memengaruhi pergerakan harga.

Tabel di dalam Appendix 'Local Moran' menunjukkan nilai Local Moran's I dari rerata harga tepung terigu antar provinsi di Indonesia selama periode 2018 hingga 2023. Local Moran's I adalah ukuran statistik yang digunakan untuk mengevaluasi adanya korelasi spasial lokal, yang menggambarkan bagaimana suatu variabel (dalam hal ini harga tepung terigu) berkorelasi di wilayah-wilayah tetangga. Nilai Local Moran's I berkisar dari -1 hingga +1, di mana nilai mendekati +1 menunjukkan adanya korelasi spasial positif (provinsi tetangga memiliki harga yang serupa), nilai mendekati -1 menunjukkan korelasi spasial negatif (provinsi tetangga memiliki harga yang berbeda), dan nilai mendekati 0 menunjukkan tidak adanya pola spasial yang jelas.

Dari hasil dalam tabel, terlihat bahwa beberapa provinsi memiliki korelasi spasial yang positif secara konsisten, seperti Jawa Tengah, Jawa Barat, dan Yogyakarta, yang menunjukkan bahwa harga tepung terigu di provinsi-provinsi ini cenderung serupa dengan provinsi tetangga mereka. Sebagai contoh, nilai Local Moran's I untuk Jawa Tengah terus meningkat dari 0,463 pada tahun 2018 menjadi 0,650 pada tahun 2023, mengindikasikan adanya pola yang semakin kuat di mana harga tepung terigu di provinsi tersebut berkorelasi positif dengan harga di provinsi tetangganya.

Di sisi lain, beberapa provinsi menunjukkan fluktuasi dalam nilai Local Moran's I, seperti Banten dan Bali, yang pada beberapa tahun menunjukkan korelasi positif yang kuat, namun pada tahun-tahun lain nilainya menurun atau stagnan. Ini bisa mengindikasikan adanya dinamika harga di wilayah-wilayah tersebut yang lebih dipengaruhi oleh faktor-faktor lokal dibandingkan dengan pengaruh dari provinsi tetangganya.

Beberapa provinsi seperti Bengkulu dan Kalimantan Tengah secara konsisten menunjukkan nilai Local Moran's I negatif atau mendekati nol, yang mengindikasikan bahwa harga tepung terigu di provinsi tersebut cenderung tidak berkorelasi dengan harga di provinsi tetangga atau mungkin memiliki pola harga yang berbeda. Misalnya, Bengkulu memiliki nilai yang sangat rendah di seluruh periode, bahkan mencapai -1,036 pada tahun 2018, yang menunjukkan bahwa harga di provinsi ini sangat berbeda dibandingkan dengan provinsi di sekitarnya.

Secara keseluruhan, tabel ini memberikan wawasan tentang distribusi spasial harga tepung terigu di seluruh Indonesia dan menunjukkan bagaimana keterkaitan harga antar provinsi telah berubah dari tahun ke tahun. Hal ini penting dalam analisis harga pangan karena memungkinkan identifikasi wilayah-wilayah di mana kebijakan harga dapat lebih difokuskan untuk mengurangi disparitas atau ketidakstabilan harga antar wilayah.

4.3.4 Penggunaan Data Ekonomi untuk Peramalan Harga Komoditas Tepung Terigu dan Minyak Goreng

Dalam penelitian ini, kami menggunakan berbagai sumber data sebagai pendukung peramalan harga komoditas tepung terigu dan minyak goreng. Data seperti *Harga Konsumen Rata-rata Pedesaan: Tepung Beras* dan *Harga Konsumen Rata-rata Pedesaan: Tepung Gandum* penting untuk memahami dinamika harga bahan baku pangan di pedesaan, yang dapat mempengaruhi permintaan dan penawaran dari dua komoditas ini. Selain itu, data dari *GAPKI: Ekspor: Minyak Sawit Mentah (CPO)*, *Ekspor Pertanian: Nilai: Minyak Sawit Mentah*, dan *Ekspor: Volume: Minyak Sawit Mentah* digunakan untuk menangkap tren ekspor CPO, yang merupakan salah satu bahan utama produksi minyak goreng.

Kami juga mempertimbangkan data impor seperti *Impor: Nilai: Minyak Sawit Mentah* untuk mengukur seberapa besar ketergantungan domestik terhadap minyak sawit mentah impor, yang secara langsung berdampak pada harga komoditas minyak goreng. Data *Indikator Internasional: Harga Komoditas Internasional: Minyak Sawit Mentah (CPO)* juga digunakan untuk memahami harga minyak sawit di pasar internasional, karena fluktuasi harga global dapat mempengaruhi harga domestik.

Selanjutnya, data terkait *Indeks Harga Perdagangan Internasional* baik untuk kelompok komoditas ekspor maupun impor seperti *Persiapan dari Sereal, Tepung, Pati, atau Susu*, serta *Biji Minyak, Biji-bijian, Tumbuhan* sangat relevan untuk memantau harga komoditas yang berkaitan dengan proses produksi tepung terigu dan minyak goreng. Indeks ini mencerminkan dinamika harga di tingkat global yang mempengaruhi biaya produksi domestik dan kemampuan ekspor.

Penggunaan data *Indikator Utama CEIC: Indonesia* membantu dalam menganalisis indikator makroekonomi yang mempengaruhi perekonomian secara keseluruhan, sementara data terkait *Indeks Nilai Tukar Nominal Efektif* dan *Indeks Nilai Tukar Riil Efektif* digunakan untuk memahami dampak fluktuasi nilai tukar terhadap harga komoditas ekspor dan impor, yang dapat mempengaruhi harga domestik komoditas tepung terigu dan minyak goreng.

Terakhir, *Indeks Harga Grosir: Umum* dan *Indeks Harga Grosir: Pertanian* digunakan untuk menangkap dinamika harga grosir secara keseluruhan dan spesifik dalam sektor pertanian yang secara langsung mempengaruhi pasar tepung terigu dan minyak goreng. Data ini memberikan gambaran umum mengenai inflasi harga grosir dan bagaimana hal itu berdampak pada harga akhir di tingkat konsumen.

Secara lengkap, berikut merupakan daftar data ekonomi yang kami gunakan.

- Harga Konsumen Rata-rata Pedesaan: Tepung Beras
- Harga Konsumen Rata-rata Pedesaan: Tepung Gandum
- GAPKI: Ekspor: Minyak Sawit Mentah (CPO)
- Ekspor Pertanian: Nilai: Minyak Sawit Mentah
- Ekspor: Volume: Minyak Sawit Mentah
- Impor: Nilai: Minyak Sawit Mentah
- Indikator Internasional: Harga Komoditas Internasional: Minyak Sawit Mentah (CPO)

- Indeks Harga Perdagangan Internasional: Kelompok Komoditas Impor: Persiapan dari Sereal, Tepung, Pati, atau Susu
- Indeks Harga Perdagangan Internasional: Kelompok Komoditas Ekspor: Persiapan dari Sereal, Tepung, Pati, atau Susu
- Indeks Harga Perdagangan Internasional: Kelompok Komoditas Impor: Biji Minyak, Biji-bijian, Tumbuhan
- Indeks Harga Perdagangan Internasional: Kelompok Komoditas Ekspor: Biji Minyak, Biji-bijian, Tumbuhan
- Indikator Utama CEIC: Indonesia
- Indeks Nilai Ekspor: HS: 19: Olahan dari Tepung
- Indeks Nilai Impor: HS 12: Biji Minyak, Biji-bijian, Biji & Buah
- Indeks Nilai Impor: HS 19: Persiapan dari Sereal, Tepung, Pati, Susu
- Indeks Nilai Tukar Nominal Efektif: BIS: 2020=100: Lebar
- Indeks Nilai Tukar Riil Efektif: BIS: 2020=100: Lebar
- Indeks Harga Grosir: Umum
- Indeks Harga Grosir: Pertanian

Penggunaan data ini bertujuan untuk mendapatkan gambaran yang lebih komprehensif tentang faktor-faktor yang mempengaruhi harga minyak goreng dan tepung terigu, baik dari sisi domestik maupun internasional.

Grafik 1 menunjukkan pergerakan harga dari beberapa komoditas utama di Indonesia, termasuk harga tepung terigu di pedesaan, harga internasional CPO, harga ekspor dan impor olahan tepung terigu, serta harga beras di pedesaan selama periode 2018 hingga 2024.

Grafik pertama di kiri atas menunjukkan tren peningkatan harga tepung terigu di pedesaan yang cenderung naik secara konsisten mulai tahun 2020 hingga 2024, dengan peningkatan tajam yang terjadi sekitar tahun 2022. Hal ini menunjukkan bahwa ada faktor yang signifikan mempengaruhi kenaikan harga tepung terigu di pedesaan selama periode tersebut.

Grafik kedua di kanan atas menunjukkan fluktuasi harga internasional CPO (Crude Palm Oil). Harga CPO internasional mengalami peningkatan yang tajam pada tahun 2021 hingga mencapai puncaknya di tahun 2022 sebelum kembali menurun mendekati akhir 2023. Fluktuasi ini dapat disebabkan oleh berbagai faktor global seperti permintaan dan penawaran minyak sawit serta dinamika pasar internasional.

Grafik di kiri bawah memperlihatkan harga ekspor dan impor olahan tepung terigu. Terlihat bahwa harga impor menunjukkan tren yang lebih tinggi daripada harga ekspor, dengan peningkatan tajam pada harga impor setelah tahun 2022. Peningkatan ini mencerminkan adanya kenaikan biaya impor yang signifikan, yang kemungkinan disebabkan oleh tekanan harga internasional atau kebijakan perdagangan.




Figure 1: Pergerakan Harga Komoditas Utama di Indonesia: Tepung Terigu, Minyak Sawit, dan Beras (2018-2024)

Grafik terakhir di kanan bawah menampilkan pergerakan harga beras di pedesaan. Sama seperti tepung terigu, harga beras di pedesaan juga menunjukkan tren kenaikan yang konsisten mulai dari tahun 2020 hingga 2024. Kenaikan ini dapat mengindikasikan adanya peningkatan biaya produksi atau faktor-faktor lain yang mempengaruhi pasokan dan permintaan beras di tingkat pedesaan.

Secara keseluruhan, grafik-grafik ini memberikan gambaran yang jelas mengenai tren harga komoditas penting di Indonesia dan menunjukkan adanya hubungan antara pasar internasional dan harga domestik, khususnya untuk komoditas seperti minyak sawit mentah dan tepung terigu.

Grafik 2 menampilkan data terkait ekspor dan impor minyak sawit mentah (CPO) di Indonesia dari tahun 2018 hingga 2024. Pada bagian kiri atas, grafik menunjukkan total ekspor CPO yang dilaporkan oleh GAPKI. Dari grafik ini terlihat adanya pola fluktuasi yang kuat, terutama pada tahun 2020 hingga 2022, di mana ekspor CPO mengalami penurunan yang cukup tajam. Namun, terdapat periode di mana ekspor CPO mengalami kenaikan yang signifikan, terutama pada awal tahun 2021.

Grafik di kanan atas memperlihatkan total nilai ekspor CPO yang secara umum mengikuti tren ekspor CPO dalam hal volume, namun terdapat variasi yang mungkin dipengaruhi oleh harga interna-




Figure 2: Dinamika Ekspor, Import, dan Harga Minyak Sawit Mentah (CPO) Indonesia: 2018-2024

sional CPO. Nilai ekspor CPO tampak mengalami kenaikan yang signifikan pada beberapa periode di tahun 2021 dan 2022, yang kemungkinan besar disebabkan oleh peningkatan harga internasional CPO.

Pada bagian kiri bawah, grafik volume ekspor CPO menunjukkan pola yang hampir mirip dengan grafik total ekspor CPO. Volume ekspor mengalami fluktuasi yang cukup signifikan selama periode 2018 hingga 2024. Penurunan volume yang tajam pada tahun 2022 menjadi salah satu fitur menonjol dari grafik ini.

Di bagian kanan bawah, grafik menunjukkan perbandingan antara harga ekspor dan impor CPO. Terlihat bahwa harga ekspor CPO mengalami peningkatan yang stabil dari tahun 2018 hingga 2024. Sebaliknya, harga impor CPO relatif stabil dan lebih rendah dibandingkan dengan harga ekspor, meskipun terdapat beberapa fluktuasi kecil dalam periode tersebut.

Secara keseluruhan, grafik ini menggambarkan dinamika perdagangan CPO di Indonesia, baik dari sisi volume ekspor-impor maupun dari sisi nilai dan harga. Kenaikan harga ekspor menunjukkan peningkatan permintaan global terhadap CPO, sementara fluktuasi volume ekspor-impor mencerminkan kondisi pasar global yang dinamis. Faktor eksternal seperti kebijakan perdagangan dan kondisi pasar internasional mungkin menjadi faktor utama dalam fluktuasi ini.




Figure 3: Tren Ekspor-Impor, Nilai Tukar, dan Indeks Harga Grosir untuk Komoditas Tepung Terigu dan Minyak Olahan, 2018-2024

Grafik 3 memberikan gambaran tentang tren ekspor-impor dan berbagai indikator ekonomi dari tahun 2018 hingga 2024. Grafik pertama di kiri atas menunjukkan nilai ekspor-impor olahan tepung terigu yang tampak cukup stabil sepanjang periode hingga tahun 2022, meskipun ada fluktuasi besar pada tahun 2020 dan peningkatan signifikan menjelang tahun 2022. Hal ini menunjukkan bahwa terjadi perubahan tajam dalam perdagangan tepung terigu, kemungkinan dipengaruhi oleh gangguan ekonomi atau kebijakan perdagangan yang diimplementasikan selama periode tersebut.

Pada grafik kanan atas, terlihat volume impor olahan minyak yang menunjukkan tren peningkatan yang signifikan sejak tahun 2020, dengan puncaknya sekitar tahun 2022, sebelum akhirnya menurun lagi pada tahun 2024. Peningkatan impor ini bisa jadi merupakan respons terhadap peningkatan permintaan domestik atau harga internasional yang kompetitif untuk minyak olahan.

Grafik kiri bawah menampilkan nilai nominal dan riil ERR (Exchange Rate Real), di mana kedua indikator ini tampak bergerak dalam pola yang hampir sama, meskipun ada beberapa fluktuasi terutama pada periode sekitar tahun 2020 dan awal 2021. Ini menunjukkan adanya dinamika dalam nilai tukar yang mungkin terkait dengan faktor-faktor global maupun domestik, termasuk kebijakan

moneter atau pergerakan ekonomi global.

Grafik kanan bawah memperlihatkan Indeks Harga Grosir (Wholesale Price Index, WPI) umum dan untuk sektor pertanian. Secara keseluruhan, indeks harga grosir menunjukkan tren peningkatan yang stabil sejak tahun 2018, terutama pada sektor pertanian yang mengalami peningkatan signifikan sejak awal 2021. Tren ini dapat menunjukkan peningkatan biaya produksi atau perubahan harga di pasar domestik dan internasional, yang mempengaruhi harga grosir untuk komoditas pertanian dan produk secara umum.

5 Estimasi maksimum likelihood dari factor model pada dataset dengan pola data hilang yang sembarang.

Peneliti mengikuti estimasi sesuai penelitian dari Banbura dan Modugno (2014) dalam melakukan peramalan harga Minyak Goreng Curah Kemasan Curah, Minyak Goreng Sawit Kemasa Premium, dan Tepung Terigu.

Penelitian tentang Dynamic Factor Models (DFM) telah mengalami perkembangan pesat sejak kontribusi awal dari Geweke (1977) dan Sargent dan Sims (1977), di mana model ini digunakan untuk keperluan peramalan, analisis struktural, dan konstruksi indikator ekonomi. Salah satu ide utama di balik model faktor adalah bahwa pergerakan bersama secara dinamis dari banyak variabel yang diamati dapat diringkas oleh sejumlah faktor yang tidak teramati (latent factors) (Stock dan Watson, 1989, 2002b; Quah dan Sargent, 1993; Bernanke dan Boivin, 2003). Namun, karena faktor-faktor tersebut tidak diamati langsung, estimasi maximum likelihood tidak dapat diturunkan secara eksplisit dan umumnya memerlukan pendekatan algoritma optimasi (Engle dan Watson, 1981; Stock dan Watson, 1989).

Banbura dan Modugno (2014) membangun metodologi yang berakar pada pendekatan dari Watson dan Engle (1983) serta Shumway dan Stoffer (1982), yang menggunakan algoritma Expectation Maximization (EM) untuk mengestimasi parameter DFM dalam kasus dengan pola data yang hilang secara umum. Penelitian ini berfokus pada modifikasi algoritma EM untuk menangani data yang hilang dalam bentuk yang lebih kompleks, sebuah kondisi yang sering muncul dalam dataset ekonomi, khususnya untuk wilayah seperti zona Euro di mana beberapa indikator ekonomi hanya tersedia dalam frekuensi rendah atau waktu yang terbatas. Beberapa studi terdahulu telah mencoba menangani masalah data yang hilang, tetapi kebanyakan terbatas pada kasus di mana hubungan antara variabel observasi dan faktor dianggap tetap dan diketahui (Shumway dan Stoffer, 1982; Reis dan Watson, 2010).

Metodologi yang diajukan oleh Banbura dan Modugno menawarkan solusi yang efisien secara komputasi bahkan untuk dataset yang besar. Salah satu kontribusi penting dari penelitian ini adalah kemampuannya untuk menangani data yang hilang dalam pola yang kompleks dan dataset dengan frekuensi campuran, yang merupakan tantangan besar dalam ekonomi makro modern. Selain itu, pendekatan maximum likelihood lebih unggul dibandingkan dengan metode non-parametrik seperti principal components dalam hal efisiensi sampel kecil dan kemampuan otomatis untuk menangani data yang hilang, seperti yang ditunjukkan oleh Doz et al. (2008).

Penelitian Banbura dan Modugno juga relevan dengan penelitian-penelitian sebelumnya yang menangani peramalan ekonomi dalam konteks data yang hilang dan frekuensi campuran, seperti Gian-

none et al. (2008) yang mengembangkan alat untuk nowcasting dengan menggunakan model faktor. Meskipun metodologi mereka populer, pendekatan tersebut memiliki keterbatasan dalam menangani data frekuensi campuran yang lebih kompleks atau berbagai pola data yang hilang. Dengan memperluas kemampuan metode ini, Banbura dan Modugno menunjukkan bahwa model DFM dapat diimplementasikan dengan sukses dalam aplikasi ekonomi makro, seperti nowcasting GDP di zona Euro.

Melalui eksperimen Monte Carlo, Banbura dan Modugno (2014) menunjukkan keunggulan metode mereka dibandingkan dengan algoritma EM yang diusulkan oleh Stock dan Watson (2002b) dan Rubin dan Thayer (1982), terutama dalam konteks data yang hilang. Mereka juga menunjukkan bahwa model mereka mampu meningkatkan akurasi peramalan dibandingkan dengan model univariat dan pendekatan model skala besar yang digunakan dalam literatur nowcasting lainnya. Hasil-hasil ini menegaskan pentingnya pemodelan yang efisien dalam menghadapi tantangan empiris seperti data yang hilang dan struktur dinamis dalam peramalan ekonomi.

5.1 Temuan Utama

5.1.1 Minyak Goreng




Figure 4: Data untuk Peramalan Harga Minyak Goreng

Grafik 3 menunjukkan data harga minyak goreng, baik minyak goreng sawit curah maupun kemasan premium, yang telah mengalami tiga jenis transformasi: transformasi log, differencing pertama (first difference), dan standarisasi. Transformasi log digunakan untuk menstabilkan varians data, sehingga

perubahan proporsional dalam nilai besar dan kecil diperlakukan secara serupa. Differencing pertama diterapkan untuk menghilangkan tren jangka panjang dalam data, menjadikannya stasioner dengan fokus pada perubahan antar periode waktu. Standarisasi dilakukan agar semua seri memiliki rata-rata nol dan standar deviasi satu, sehingga memungkinkan perbandingan antar wilayah tanpa dipengaruhi oleh skala asli masing-masing data.

Dari grafik tersebut, terlihat adanya fluktuasi yang tinggi, terutama pada periode 2020 hingga 2022, yang mungkin mencerminkan dampak faktor-faktor eksternal seperti perubahan harga internasional, kondisi ekonomi, atau kebijakan terkait minyak goreng, terutama selama pandemi. Setelah periode 2022, meskipun volatilitas menurun, fluktuasi harga tetap terjadi, meskipun dengan intensitas yang lebih rendah.

Sebagian besar data berkumpul di sekitar sumbu nol, mengindikasikan bahwa setelah standarisasi, variabel-variabel tersebut memiliki deviasi yang tidak terlalu besar dari rata-rata. Namun, terdapat beberapa outlier atau lonjakan tajam pada beberapa titik waktu yang menandakan adanya perubahan harga yang signifikan di beberapa provinsi atau jenis minyak goreng, baik curah maupun kemasan premium.

Secara keseluruhan, grafik ini menggambarkan dinamika perubahan harga minyak goreng di berbagai provinsi di Indonesia, mulai dari Aceh, Bali, hingga Sulawesi dan Papua, yang mengalami periode volatilitas tinggi, terutama pada masa krisis, dan stabilisasi setelahnya. Analisis lebih lanjut diperlukan untuk memahami penyebab spesifik dari fluktuasi besar tersebut, seperti hubungannya dengan harga internasional CPO, kebijakan pemerintah, atau perubahan dalam permintaan dan pasokan di pasar domestik.

Pemilihan rank dan lag berdasarkan berbagai skenario di bagian appendix menunjukkan bahwa penggunaan rank 2 atau 3 bisa menjadi pilihan yang lebih tepat dibandingkan rank yang lebih tinggi (seperti rank 4 atau 5).

Tabel pada bagian Appendix menunjukkan perbedaan yang jelas antara rank dan lag dalam model Dynamic Factor Model (DFM). Pada rank 2 ($r2p1$ hingga $r2p3$), terlihat bahwa seiring bertambahnya lag dari 1 ke 3, nilai dalam matriks transisi berubah secara signifikan. Ini terutama terlihat dengan munculnya lebih banyak koefisien tambahan seperti $L2$ dan $L3$ saat lag bertambah, yang mengindikasikan adanya penambahan kompleksitas dalam dinamika faktor laten. Pada rank 3 dan 4, model dengan lebih banyak faktor menunjukkan variasi yang lebih kompleks dalam faktor transisi antar lag. Ini menunjukkan bahwa terdapat lebih banyak interaksi antara faktor-faktor laten, yang menambah kedalaman dinamika model. Rank 5 menghadirkan tantangan yang lebih besar, karena menambah faktor tambahan dalam rank ini menyebabkan matriks transisi menjadi lebih rumit. Peningkatan lag dalam rank ini cenderung memperkenalkan lebih banyak interaksi antar faktor, yang mencerminkan dinamika yang lebih kaya, tetapi juga lebih rumit.

Koefisien yang lebih besar di elemen off-diagonal mulai terlihat saat rank dan lag semakin besar. Semakin besar lag dan rank, terdapat lebih banyak koefisien non-diagonal yang signifikan, terutama dalam rank 4 dan 5. Hal ini menunjukkan interaksi yang kuat antar faktor laten. Sebagai contoh, dalam skenario $r4p3$ dan $r5p3$, interaksi antar faktor menjadi sangat kuat dengan nilai-nilai yang relatif besar di luar elemen diagonal.

Ketika rank dan lag bertambah, Factor Transition Matrix cenderung menjadi lebih kompleks. Hal

ini menunjukkan bahwa model menangkap lebih banyak dinamika antar faktor laten. Meskipun ini bisa menguntungkan dalam menjelaskan variasi yang lebih detail dalam data, terlalu banyak interaksi antar faktor atau koefisien yang sangat besar dapat menjadi indikasi bahwa model mulai kehilangan parsimony dan mungkin mengalami overfitting.

Berdasarkan hasil yang kami sajikan dan beberapa pertimbangan dalam analisis Dynamic Factor Model (DFM), penggunaan rank 2 atau 3 dapat menjadi pilihan yang lebih tepat dibandingkan rank yang lebih tinggi seperti 4 atau 5. Hal ini didasari oleh prinsip parsimony, yang menyarankan agar model tetap sederhana namun cukup untuk menangkap informasi utama dari data. Dengan menggunakan rank 2 atau 3, kami dapat menangkap dua atau tiga faktor laten yang berpengaruh besar, tanpa menambahkan terlalu banyak faktor yang justru bisa mengarah pada overfitting. Rank yang lebih tinggi cenderung menangkap lebih banyak detail, tetapi sering kali detail ini lebih merefleksikan noise daripada sinyal yang sebenarnya. Akibatnya, model menjadi terlalu terfokus pada data spesifik yang ada dalam sampel dan kurang mampu menangani data di luar sampel.

Selain itu, dengan menggunakan rank 2 atau 3, Factor Transition Matrix akan lebih sederhana dan lebih mudah diinterpretasikan secara ekonomi. Model dengan rank yang lebih rendah cenderung menghasilkan faktor laten yang menangkap dinamika utama yang lebih relevan, sementara rank yang lebih tinggi mungkin memberikan hasil yang sulit diinterpretasikan karena adanya koefisien besar yang tidak konsisten.

Menggunakan rank 2 atau 3 juga menciptakan keseimbangan antara fit dan generalisasi. Ini berarti bahwa model dapat menangkap dinamika penting tanpa menjadi terlalu rumit, sehingga tetap robust saat diterapkan pada data di luar sampel. Sebagai tambahan, model dengan rank yang lebih rendah biasanya memiliki Factor Transition Matrix yang lebih stabil, dengan koefisien yang tidak terlalu bervariasi antara lag dan faktor, sehingga hasilnya lebih dapat diandalkan. Dengan demikian, rank 2 atau 3 adalah pilihan yang lebih tepat untuk menjaga kesederhanaan model, stabilitas hasil, serta kemudahan interpretasi, tanpa mengorbankan kualitas prediksi yang dapat diuji secara out-of-sample.

Tabel berikut menunjukkan hasil model DFM dengan rank 2 dan lag 1.

Table 4: Summary Statistics of Factors [F] Minyak Goreng

	N	Mean	Median	SD
f1	74	9.21	-3.27	193.64
f2	74	-0.12	-0.15	6.73
f3	74	-0.02	-0.84	6.68
f4	74	-0.06	-0.02	6.55

Table 5: Factor Transition Matrix [A] Minyak Goreng

	L1.f1	L1.f2	L1.f3	L1.f4
f1	0.1463	-5.9673	2.6568	3.9783
f2	0.0018	0.6558	0.4643	-0.3840
f3	0.0086	-0.1107	0.0891	-0.1447
f4	-0.0140	-0.1484	0.6864	-0.2942

Table 6: Factor Covariance Matrix [cov(F)] Minyak Goreng

	f1	f2	f3	f4
f1	37495.89	-563.38*	-228.60	-212.38
f2	-563.38*	45.33	1.49	18.89*
f3	-228.60	1.49	44.64	-4.90
f4	-212.38	18.89*	-4.90	42.88

Table 7: Factor Transition Error Covariance Matrix [Q] Minyak Goreng

	u1	u2	u3	u4
u1	35413.55	-409.62	-312.69	-170.42
u2	-409.62	18.37	3.60	-0.35
u3	-312.69	3.60	37.67	-6.18
u4	-170.42	-0.35	-6.18	6.21

Table 8: Summary of Residual AR(1) Serial Correlations Minyak Goreng

N	Mean	Median	SD
147	-0.1882	-0.182	0.21

Table 9: Summary of Individual R-Squared's Minyak Goreng

N	Mean	Median	SD
147	0.4522	0.4646	0.3

Dari tabel Summary Statistics of Factors [F], kita dapat melihat bahwa faktor pertama (f1) memiliki nilai rata-rata (Mean) yang positif sebesar 9.21, namun dengan Median negatif sebesar -3.27 dan standar deviasi (SD) yang sangat besar, yaitu 193.64. Ini menunjukkan bahwa f1 memiliki variasi yang sangat tinggi dengan distribusi yang tidak simetris, yang mencerminkan adanya fluktuasi yang besar dalam dinamika faktor ini. Faktor kedua hingga keempat (f2, f3, dan f4) menunjukkan rata-rata yang lebih dekat ke nol dengan standar deviasi yang lebih kecil, yang menunjukkan dinamika yang lebih stabil dibandingkan f1.

Factor Transition Matrix [A] menunjukkan hubungan antar faktor dari satu periode ke periode berikutnya. Koefisien L1.f2 untuk f1 (-5.9673) menunjukkan adanya pengaruh negatif yang kuat dari f2 pada f1, sementara L1.f3 dan L1.f4 untuk f1 menunjukkan pengaruh positif. Di sisi lain, elemen diagonal, seperti L1.f1 (0.1463) untuk f1, menunjukkan pengaruh yang relatif kecil dari f1 terhadap dirinya sendiri dibandingkan dengan faktor lain. Ini mengindikasikan bahwa faktor-faktor laten saling mempengaruhi dengan cara yang kompleks, dengan beberapa interaksi yang signifikan di antara mereka.

Dari Factor Covariance Matrix [cov(F)], kita melihat bahwa variansi faktor f1 sangat besar, yaitu 37,495.89, yang menegaskan besarnya fluktuasi yang diamati pada f1 dalam tabel statistik ringkas. Terdapat beberapa elemen kovarians yang signifikan, seperti antara f1 dan f2 (-563.38), serta f2 dan f4 (18.89), yang menunjukkan adanya korelasi kuat antara beberapa faktor. Kovarians yang negatif

antara f_1 dan f_2 menunjukkan bahwa kedua faktor tersebut cenderung bergerak dalam arah yang berlawanan.

Factor Transition Error Covariance Matrix [Q] menunjukkan besarnya variansi dalam kesalahan transisi faktor. Variansi pada u_1 (35,413.55) kembali mencerminkan tingginya ketidakpastian atau kesalahan dalam prediksi untuk faktor f_1 , sementara nilai-nilai lainnya seperti u_2 dan u_3 memiliki variansi kesalahan yang jauh lebih kecil. Korelasi antara kesalahan transisi antar faktor, seperti antara u_1 dan u_2 (-409.62), juga menunjukkan adanya interaksi antara kesalahan prediksi di berbagai faktor.

Tabel Summary of Residual AR(1) Serial Correlations menunjukkan bahwa korelasi serial residu memiliki nilai rata-rata -0.1882, dengan standar deviasi sebesar 0.2092, yang mengindikasikan bahwa terdapat sedikit autokorelasi negatif dalam residu model. Ini berarti bahwa residu dari model tidak benar-benar independen antar periode, meskipun korelasi ini tidak terlalu kuat.

Terakhir, Summary of Individual R-Squared's menunjukkan bahwa rata-rata R-squared untuk semua variabel adalah 0.4522, dengan median sebesar 0.4646. Ini menunjukkan bahwa model mampu menjelaskan sekitar 45% dari variasi dalam data, yang cukup moderat. Namun, dengan standar deviasi sebesar 0.2948, terdapat variasi yang signifikan dalam performa model di antara berbagai variabel, yang berarti beberapa variabel dijelaskan dengan baik oleh model, sementara variabel lain mungkin tidak begitu baik.

Secara keseluruhan, hasil ini menunjukkan bahwa model DFM menangkap sebagian besar dinamika faktor laten, dengan interaksi yang kompleks di antara faktor-faktor tersebut. Namun, tingginya variasi dalam beberapa faktor, terutama f_1 , serta korelasi serial yang masih ada dalam residu menunjukkan bahwa model mungkin perlu disederhanakan atau disesuaikan lebih lanjut untuk meningkatkan stabilitas dan generalisasi prediksi.

Grafik 4 menunjukkan estimasi faktor terstandarisasi dari model Dynamic Factor Model (DFM) untuk dua faktor laten, yaitu f_1 dan f_2 , yang ditampilkan dalam dua panel terpisah. Grafik ini membandingkan tiga metode estimasi faktor: PCA (Principal Component Analysis), yang digambarkan dengan garis merah, TwoStep dengan garis kuning, dan QML (Quasi Maximum Likelihood) dengan garis biru.

Pada faktor pertama (f_1), garis PCA memperlihatkan pola yang halus dan cenderung stabil, meskipun terjadi penurunan bertahap di tengah periode waktu dan kenaikan kembali menjelang akhir. Ini menunjukkan bahwa PCA menghasilkan estimasi yang lebih halus dan kurang sensitif terhadap perubahan mendadak. Metode TwoStep juga menunjukkan pola yang halus dan mengikuti tren umum yang mirip dengan PCA, meskipun ada sedikit perbedaan pada beberapa titik waktu. Secara keseluruhan, garis TwoStep juga menggambarkan stabilitas yang tinggi di sebagian besar periode, dengan hanya sedikit penyimpangan dari PCA. Sebaliknya, QML menunjukkan fluktuasi yang lebih tajam dibandingkan dengan PCA dan TwoStep. QML mengalami lonjakan signifikan, terutama sekitar waktu ke-40, di mana terjadi peningkatan dan penurunan yang tajam, menunjukkan bahwa QML lebih sensitif terhadap outlier atau perubahan mendadak dalam data.

Pada faktor kedua (f_2), PCA menunjukkan penurunan tajam di awal periode, yang kemudian menjadi stabil di paruh kedua grafik. Pola ini cukup berbeda dari TwoStep dan QML, terutama pada fase awal. TwoStep mengikuti tren yang lebih stabil, dengan penurunan yang lebih lambat dibandingkan PCA di awal, tetapi kembali stabil di akhir periode, mirip dengan pola PCA. QML, seperti pada




Figure 5: Standardized Factor Estimates

faktor pertama, menunjukkan fluktuasi yang lebih besar dibandingkan dua metode lainnya. Lonjakan signifikan terjadi sekitar waktu ke-40, dan meskipun ada stabilisasi setelahnya, QML masih menunjukkan variasi yang lebih besar daripada PCA dan TwoStep, yang menunjukkan bahwa QML lebih peka terhadap variasi dalam faktor kedua.

Secara keseluruhan, grafik ini memberikan wawasan tentang perbedaan ketiga metode estimasi faktor dalam menangkap dinamika harga minyak goreng dalam model DFM. PCA dan TwoStep cenderung menunjukkan pola yang lebih halus dan stabil, terutama di paruh kedua periode, sehingga lebih cocok untuk analisis yang berfokus pada tren jangka panjang dan stabilitas. Sebaliknya, QML menunjukkan respons yang lebih tajam terhadap fluktuasi, membuatnya lebih tepat untuk menangkap perubahan cepat atau outlier signifikan dalam data. Lonjakan besar pada QML di sekitar waktu ke-40 menunjukkan adanya perubahan besar dalam data yang mungkin disebabkan oleh faktor eksternal seperti perubahan kebijakan atau peristiwa global yang memengaruhi pasar minyak goreng secara tiba-tiba. Pemilihan metode estimasi harus mempertimbangkan tujuan analisis: PCA dan TwoStep cocok untuk tren jangka panjang, sementara QML lebih efektif dalam menangkap fluktuasi jangka pendek atau perubahan mendadak.




Figure 6: Data untuk Peramalan Harga Tepung Terigu

5.1.2 Tepung Terigu

Grafik 5 yang ditampilkan merupakan hasil dari transformasi logaritmik, differencing pertama (first difference), dan standarisasi dari data harga tepung terigu di berbagai provinsi serta koefisien variansinya. Grafik ini mencakup data mulai dari Januari 2018 hingga Maret 2024. Transformasi log dilakukan untuk menstabilkan varian dalam data, sedangkan differencing pertama digunakan untuk menghilangkan tren yang ada, dengan tujuan agar pola pergerakan antarperiode lebih terlihat jelas. Standarisasi dilakukan untuk menyetarakan skala antar seri data, sehingga semua variabel memiliki rata-rata nol dan deviasi standar satu, memungkinkan perbandingan yang lebih mudah antar berbagai wilayah.

Dari grafik tersebut, dapat diamati fluktuasi yang cukup intens di seluruh seri harga tepung terigu, terutama selama periode antara 2019 hingga 2022, yang mungkin mencerminkan perubahan signifikan dalam pasar atau harga tepung terigu pada periode tersebut. Di beberapa bagian grafik, terlihat adanya lonjakan dan penurunan yang tajam, yang menunjukkan bahwa variabel-variabel ini mengalami perubahan harga yang signifikan dalam waktu yang relatif singkat. Volatilitas harga ini juga mungkin dipengaruhi oleh faktor eksternal, seperti kondisi ekonomi global, perubahan kebijakan perdagangan, atau dampak pandemi COVID-19.

Meskipun terdapat fluktuasi yang cukup tinggi, terdapat juga periode stabilitas setelah pertengahan 2022, di mana sebagian besar variabel berkumpul lebih dekat di sekitar garis nol. Hal ini

mengindikasikan bahwa meskipun harga tepung terigu di berbagai provinsi mengalami perubahan yang tajam pada periode sebelumnya, terjadi penurunan volatilitas di kemudian hari. Outlier dan perubahan tajam tetap ada di beberapa bagian, menunjukkan bahwa beberapa wilayah mungkin mengalami pergerakan harga yang lebih ekstrem daripada wilayah lainnya.

Secara keseluruhan, grafik ini menggambarkan dinamika perubahan harga tepung terigu di berbagai provinsi di Indonesia, dengan pola volatilitas tinggi selama beberapa tahun terakhir, diikuti oleh fase stabilisasi. Analisis lebih lanjut diperlukan untuk memahami faktor-faktor yang berkontribusi terhadap lonjakan harga yang terlihat, serta untuk menentukan apakah fluktuasi tersebut disebabkan oleh faktor internal seperti pasokan dan permintaan domestik, atau oleh pengaruh eksternal seperti harga komoditas global atau perubahan kebijakan impor dan ekspor.

Tabel (pada bagian Appendix tepung terigu mengenai simulasi rank dan lag) menampilkan matriks transisi faktor untuk beberapa percobaan model Dynamic Factor Model (DFM) yang diujicobakan dengan berbagai rank dan lag. Tabel pertama memperlihatkan matriks transisi untuk rank 1 (r1) dengan berbagai lag dari 1 hingga 3. Untuk rank 1 dengan lag 1 (r1p1), koefisien pada elemen L1.f1 menunjukkan bahwa faktor transisi f1 memiliki nilai negatif sebesar -0.4853. Ketika lag ditingkatkan menjadi 2 (r1p2), terdapat penambahan elemen L2.f1 yang menunjukkan adanya pengaruh dari lag sebelumnya pada transisi faktor, dengan nilai koefisien yang juga negatif, yaitu -0.3417. Peningkatan ke lag 3 (r1p3) memperlihatkan lebih banyak elemen dengan koefisien negatif, yang mengindikasikan penurunan yang lebih besar dalam faktor transisi.

Pada rank 2 (r2), perbedaan yang lebih signifikan terlihat pada koefisien L1.f2 dan L2.f2 yang mengindikasikan adanya interaksi antar faktor dalam lag yang lebih tinggi. Pada lag 1 (r2p1), nilai-nilai seperti L1.f2 (-0.5595) dan L1.f1 (0.0507) menunjukkan bahwa faktor kedua (f2) memiliki pengaruh negatif yang signifikan terhadap faktor pertama (f1). Saat lag ditingkatkan ke 2 dan 3 (r2p2 dan r2p3), terlihat adanya interaksi kompleks antara faktor-faktor dengan banyak koefisien non-diagonal yang signifikan, yang menandakan bahwa model mulai menangkap lebih banyak dinamika antar faktor.

Pada rank 3 (r3), terlihat bahwa faktor-faktor tambahan mulai menunjukkan dampak yang lebih kompleks, dengan koefisien-koefisien yang bervariasi antara positif dan negatif. Sebagai contoh, pada lag 1 (r3p1), L1.f3 memiliki koefisien yang positif (0.4927), tetapi pada lag yang lebih tinggi (r3p2 dan r3p3), koefisien-koefisien ini mulai mengalami perubahan yang lebih dinamis dan menunjukkan adanya interaksi yang lebih kompleks antara faktor-faktor laten, terutama antara f1, f2, dan f3.

Rank 4 (r4) menunjukkan kompleksitas yang lebih tinggi dalam transisi faktor, dengan interaksi kuat antara faktor-faktor laten yang tergambar dari koefisien besar di berbagai elemen matriks, seperti L1.f4 pada r4p1 yang mencapai 0.2038. Pada lag yang lebih tinggi (r4p3), dinamika ini menjadi lebih terlihat dengan koefisien non-diagonal yang besar, seperti L1.f3 (0.5728) dan L2.f3 (0.5723), yang menunjukkan interaksi signifikan antar faktor laten pada berbagai lag.

Pada rank 5 (r5), model semakin menangkap variasi antar faktor dengan banyaknya koefisien yang berfluktuasi, terutama pada L1.f3 dan L1.f5 yang menunjukkan nilai positif yang signifikan di beberapa lag. Namun, dengan adanya penambahan lag, interaksi antar faktor semakin kompleks dan beberapa koefisien menunjukkan tanda fluktuasi tajam, seperti L2.f5 yang positif pada beberapa percobaan tetapi negatif pada percobaan lainnya.

Berdasarkan hasil dari tabel tersebut, rank yang lebih tinggi seperti r3 dan r4 menangkap lebih

banyak dinamika dan interaksi antar faktor laten dibandingkan dengan rank yang lebih rendah seperti r1. Namun, peningkatan lag lebih dari 2 tampaknya tidak menambah banyak informasi tambahan yang signifikan dan justru dapat memperumit model dengan interaksi yang sulit diinterpretasikan. Oleh karena itu, kesimpulannya, rank 3 atau rank 4 dengan lag 1 dapat menjadi kombinasi yang optimal untuk menangkap kompleksitas dalam dinamika harga tepung terigu, tanpa membuat model terlalu kompleks atau overfitting.

Table 10: Summary Statistics of Factors [F] Tepung Terigu

	N	Mean	Median	SD
f1	74	-0.01	-0.3668	2.3866
f2	74	0.0101	-0.0414	2.293
f3	74	-0.0037	-0.1877	2.307

Tabel 10 memberikan ringkasan statistik dari tiga faktor laten (f1, f2, dan f3) yang diestimasi dalam model Dynamic Factor Model (DFM). Setiap faktor memiliki 74 observasi. Faktor pertama (f1) memiliki nilai rata-rata mendekati nol, tepatnya -0.01, yang menunjukkan bahwa secara keseluruhan, f1 berfluktuasi di sekitar rata-rata nol. Median untuk f1 adalah -0.3668, yang berarti setengah dari nilai f1 berada di bawah -0.3668. Simpangan baku (SD) untuk f1 sebesar 2.3866 menunjukkan bahwa ada cukup banyak variasi di sekitar nilai rata-rata. Nilai minimum dan maksimum untuk f1 masing-masing adalah -7.1519 dan 7.2788, yang menandakan bahwa f1 memiliki beberapa titik data yang jauh dari rata-rata, baik di sisi negatif maupun positif.

Faktor kedua (f2) memiliki rata-rata positif kecil sebesar 0.0101, yang mirip dengan f1 dalam hal berfluktuasi di sekitar nol, dengan median -0.0414. Simpangan baku untuk f2 sedikit lebih kecil dibandingkan f1, yaitu 2.293, menunjukkan bahwa variasinya sedikit lebih kecil. Nilai ekstrem untuk f2 berkisar dari -10.2117 hingga 6.6445, yang menunjukkan bahwa terdapat beberapa outlier, terutama di sisi negatif.

Faktor ketiga (f3) juga memiliki rata-rata mendekati nol, yakni -0.0037, dan median -0.1877, dengan simpangan baku 2.307, yang sebanding dengan f1 dan f2. Namun, f3 memiliki rentang yang paling besar di antara ketiga faktor, dengan nilai minimum -13.7228 dan maksimum 9.0572. Ini menunjukkan bahwa f3 memiliki fluktuasi yang lebih besar dibandingkan dua faktor lainnya, terutama di sisi negatif.

Secara keseluruhan, ketiga faktor laten ini menunjukkan distribusi yang simetris di sekitar nol dengan variasi yang cukup besar, yang mengindikasikan bahwa faktor-faktor ini mampu menangkap dinamika variabel tersembunyi yang mempengaruhi sistem. Namun, faktor ketiga tampaknya paling berfluktuasi, dengan beberapa outlier yang lebih ekstrem, terutama di sisi negatif.

Table 11: Factor Transition Matrix [A] Tepung Terigu

	L1.f1	L1.f2	L1.f3
f1	0.21	0.18	0.49
f2	-0.01	-0.06	0.41
f3	0.33	-0.05	-0.29

Tabel 11 menunjukkan Factor Transition Matrix [A] untuk estimasi Dynamic Factor Model (DFM)

dengan rank 3 dan lag 1. Matriks ini merepresentasikan hubungan antar faktor laten (f1, f2, f3) dan bagaimana nilai faktor pada waktu sebelumnya (lag 1) mempengaruhi nilai faktor pada waktu sekarang.

Faktor pertama (f1) menunjukkan koefisien positif untuk semua faktor laten sebelumnya (L1.f1, L1.f2, L1.f3), dengan koefisien terbesar pada L1.f3 sebesar 0.49. Hal ini menunjukkan bahwa perubahan pada faktor ketiga di waktu sebelumnya memiliki pengaruh terbesar terhadap faktor pertama di waktu sekarang, sedangkan L1.f1 dan L1.f2 juga memberikan kontribusi positif yang lebih kecil.

Faktor kedua (f2) memiliki koefisien negatif pada L1.f1 (-0.01) dan L1.f2 (-0.06), tetapi koefisien positif sebesar 0.41 pada L1.f3. Ini menunjukkan bahwa faktor ketiga pada periode sebelumnya memiliki pengaruh signifikan terhadap faktor kedua saat ini, sementara faktor pertama dan kedua dari periode sebelumnya memberikan kontribusi negatif kecil.

Faktor ketiga (f3) menunjukkan pengaruh positif dari L1.f1 (0.33), sedikit negatif dari L1.f2 (-0.05), dan pengaruh negatif yang cukup besar dari L1.f3 (-0.29). Ini menunjukkan bahwa perubahan dalam faktor pertama di waktu sebelumnya memiliki pengaruh positif yang lebih besar terhadap faktor ketiga di waktu sekarang, sementara faktor kedua memiliki sedikit pengaruh negatif dan faktor ketiga di waktu sebelumnya memberikan kontribusi negatif yang signifikan.

Matriks transisi ini menunjukkan bahwa faktor-faktor dalam model memiliki saling keterkaitan, dengan faktor ketiga memainkan peran penting dalam mempengaruhi nilai faktor lainnya di periode berikutnya. Koefisien positif dan negatif menunjukkan arah hubungan, di mana nilai positif berarti hubungan searah dan nilai negatif berarti hubungan berlawanan.

Table 12: Factor Covariance Matrix [cov(F)] Tepung Terigu

	f1	f2	f3
f1	5.70	0.96	-0.35
f2	0.96	5.26	-0.33
f3	-0.35	-0.33	5.32

Tabel 12 menunjukkan Factor Covariance Matrix [cov(F)] dari hasil estimasi dengan rank 3 dan lag 1 untuk data tepung terigu. Matriks kovarians ini memberikan informasi mengenai seberapa erat faktor-faktor laten (f1, f2, f3) berhubungan satu sama lain, baik secara diagonal maupun off-diagonal.

Nilai diagonal (f1, f1; f2, f2; f3, f3) mencerminkan varians dari masing-masing faktor. Varians tertinggi terjadi pada faktor f1 dengan nilai 5.70, menunjukkan bahwa f1 memiliki tingkat fluktuasi terbesar dibandingkan f2 dan f3, yang memiliki varians sebesar 5.26 dan 5.32. Artinya, f1 mengalami variasi yang lebih besar dalam data tepung terigu dibandingkan dua faktor lainnya.

Nilai off-diagonal (f1, f2; f1, f3; f2, f3) mencerminkan kovarians atau hubungan antar faktor. Kovarians antara f1 dan f2 adalah 0.96, menunjukkan adanya hubungan positif yang cukup kuat antara kedua faktor ini. Kovarians antara f1 dan f3 (-0.35) serta antara f2 dan f3 (-0.33) adalah negatif, yang menunjukkan bahwa kedua pasangan faktor ini cenderung bergerak dalam arah yang berlawanan, meskipun hubungan tersebut tidak terlalu kuat.

Matriks ini mengindikasikan bahwa f1 dan f2 memiliki hubungan yang cukup erat dan searah, sementara f1 dan f3, serta f2 dan f3, cenderung memiliki hubungan yang negatif namun dengan korelasi

yang lemah. Analisis ini membantu memahami bagaimana faktor-faktor dalam model saling memengaruhi dan seberapa besar fluktuasi yang terjadi pada masing-masing faktor dalam data tepung terigu.

Table 13: Factor Transition Error Covariance Matrix [Q] Tepung Terigu

	u1	u2	u3
u1	4.30	-0.13	0.13
u2	-0.13	4.72	0.58
u3	0.13	0.58	4.39

Tabel 13 menunjukkan Factor Transition Error Covariance Matrix [Q], yang mengukur kovarians kesalahan transisi antara faktor-faktor laten dalam model Dynamic Factor Model (DFM). Matriks ini mencerminkan ketidakpastian atau kesalahan dalam estimasi faktor transisi antar faktor.

Nilai diagonal (u1, u1; u2, u2; u3, u3) mengindikasikan varians dari kesalahan transisi untuk masing-masing faktor laten. Nilai varians tertinggi terdapat pada u2 dengan 4.72, diikuti oleh u3 dengan 4.39 dan u1 dengan 4.30. Ini menunjukkan bahwa faktor kedua (u2) memiliki ketidakpastian terbesar dalam estimasi transisinya, sementara faktor pertama (u1) memiliki ketidakpastian yang paling rendah.

Nilai off-diagonal (misalnya, u1, u2 = -0.13 dan u2, u3 = 0.58) menunjukkan kovarians antara kesalahan transisi antar faktor. Kovarians yang negatif antara u1 dan u2 (-0.13) menunjukkan adanya sedikit hubungan berlawanan arah antara kesalahan pada faktor u1 dan u2. Sebaliknya, kovarians positif antara u2 dan u3 (0.58) menunjukkan bahwa kesalahan dalam transisi faktor u2 dan u3 cenderung bergerak searah, meskipun dengan hubungan yang moderat.

Secara keseluruhan, matriks ini membantu memahami tingkat ketidakpastian dalam proses transisi faktor-faktor laten dalam model. Faktor kedua (u2) tampaknya paling tidak stabil dalam proses transisinya, sedangkan hubungan antar kesalahan transisi antar faktor menunjukkan pola yang bervariasi, dengan beberapa faktor menunjukkan korelasi positif dan yang lainnya negatif.

Table 14: Summary of Residual AR(1) Serial Correlations

N	Mean	Median	SD
78	-0.17	-0.17	0.23

Tabel 14 memberikan ringkasan dari AR(1) serial correlations untuk residual dari model Dynamic Factor Model (DFM). AR(1) atau autoregressive order 1 serial correlation mengukur sejauh mana nilai residual di setiap titik waktu berkorelasi dengan nilai residual pada waktu sebelumnya.

Dari tabel, jumlah observasi (N) adalah 78, yang mengindikasikan jumlah residual yang dihitung untuk analisis ini. Nilai mean dari serial correlations adalah -0.17, yang berarti bahwa secara rata-rata, terdapat korelasi negatif antara residual pada dua periode berturut-turut. Korelasi negatif ini menunjukkan bahwa residual cenderung berosilasi dari periode ke periode—jika residual pada suatu periode bernilai positif, maka ada kecenderungan untuk bernilai negatif pada periode berikutnya.

Nilai median adalah -0.17, yang serupa dengan rata-rata, menunjukkan bahwa sebagian besar korelasi antar residual juga negatif. Ini menunjukkan bahwa distribusi korelasi tidak terlalu asimetris.

Standar deviasi (SD) sebesar 0.23 menunjukkan bahwa ada variasi moderat dalam korelasi residual

antar periode. Beberapa residual mungkin memiliki korelasi negatif yang lebih kuat atau lebih lemah dibandingkan rata-rata.

Hasil ini menunjukkan bahwa residual dari model memiliki sifat serial correlation negatif, yang dapat menunjukkan bahwa model DFM menangkap dinamika serial antar periode cukup baik, namun model ini mungkin masih perlu disesuaikan lebih lanjut untuk mengurangi korelasi sisa di antara waktu yang berdekatan.

Table 15: Summary of Individual R-Squared's

N	Mean	Median	SD
78	0.2315	0.161	0.2244

Tabel di atas merangkum statistik nilai R-Squared individual dari model yang digunakan. R-Squared adalah ukuran yang menunjukkan seberapa baik model menjelaskan variabilitas dalam data. Tabel ini menunjukkan bahwa terdapat 78 pengamatan dengan nilai rata-rata R-Squared sebesar 0.2315, yang berarti secara rata-rata, model mampu menjelaskan sekitar 23.15% dari variasi dalam data. Median R-Squared adalah 0.161, menunjukkan bahwa setengah dari pengamatan memiliki R-Squared di bawah 16.1%. Nilai standar deviasi (SD) sebesar 0.2244 mengindikasikan adanya variasi yang cukup besar antara nilai-nilai R-Squared pada pengamatan yang berbeda. Dari hasil ini, dapat disimpulkan bahwa model secara keseluruhan cukup mampu menjelaskan variasi dalam data dengan baik.

Grafik 4 menunjukkan estimasi faktor terstandarisasi dari model Dynamic Factor Model (DFM) dengan tiga faktor laten, yaitu f_1 , f_2 , dan f_3 , yang masing-masing ditampilkan dalam panel terpisah. Grafik ini juga membandingkan hasil estimasi menggunakan tiga metode estimasi: PCA (Principal Component Analysis) yang ditunjukkan dengan garis merah, TwoStep yang digambarkan dengan garis kuning, dan QML (Quasi Maximum Likelihood) yang digambarkan dengan garis biru.

Pada faktor pertama (f_1), ketiga metode estimasi—PCA, TwoStep, dan QML—menunjukkan pola fluktuasi yang mirip. Namun, ada sedikit perbedaan di sekitar titik-titik tertentu, terutama dalam periode pertengahan hingga akhir, di mana QML (garis biru) cenderung lebih responsif terhadap fluktuasi mendadak dibandingkan PCA dan TwoStep. Garis QML juga menunjukkan lonjakan yang lebih tajam di beberapa titik waktu.

Untuk faktor kedua (f_2), pola fluktuasi ketiga metode lebih bervariasi. Pada periode di sekitar waktu ke-20, terdapat lonjakan tajam yang lebih jelas pada metode PCA dan TwoStep, sementara QML tetap stabil sebelum mengikuti pola yang mirip setelahnya. Hal ini menunjukkan bahwa metode PCA dan TwoStep mungkin lebih sensitif terhadap perubahan signifikan di faktor kedua pada waktu tersebut.

Faktor ketiga (f_3) menunjukkan fluktuasi yang lebih halus dibandingkan dengan dua faktor sebelumnya. Ketiga metode mengikuti pola yang sangat mirip, meskipun QML sedikit lebih berfluktuasi pada periode awal dan akhir. Di pertengahan waktu, ketiga metode cenderung menunjukkan konsistensi dalam tren.

Grafik 4 mengindikasikan bahwa PCA, TwoStep, dan QML memiliki performa yang cukup seimbang dalam menangkap faktor-faktor laten pada data yang digunakan, dengan QML lebih sensitif terhadap




Figure 7: Standardized Factor Estimates

perubahan mendadak. Pilihan metode estimasi bisa bergantung pada tujuan analisis, di mana QML mungkin lebih baik dalam menangkap outlier atau perubahan tiba-tiba, sementara PCA dan TwoStep lebih konsisten dalam menunjukkan tren umum.

5.2 Evaluasi Peramalan 6 bulan ke depan (di luar Sample)

Kami menggunakan data training yang mencakup observasi dari bulan Januari 2018 hingga April 2024 untuk melakukan peramalan harga selama 6 bulan ke depan, yaitu sampai dengan bulan September 2024. peramalan ini dilakukan untuk tiga komoditas, yaitu minyak goreng sawit curah (kemasan curah), minyak goreng sawit premium (kemasan premium), dan tepung terigu. Setelah melakukan peramalan harga untuk ketiga komoditas tersebut, kami mengevaluasi akurasi hasil peramalan dengan menghitung absolute error (Abs Error) dan absolute percentage error (Pct Error) antara harga hasil peramalan dan harga observasi atau harga tes yang sebenarnya. Evaluasi ini memberikan gambaran seberapa dekat hasil peramalan kami dengan harga aktual yang terjadi selama periode uji dari Mei 2024 hingga September 2024 untuk masing-masing komoditas tersebut.

Evaluasi ini penting untuk memahami tingkat keakuratan model dan menilai sejauh mana peramalan harga tersebut dapat diandalkan. Model yang mampu memprediksi harga dengan percentage error yang kecil dianggap lebih baik dalam menangkap pola perubahan harga komoditas tersebut. Dengan melakukan evaluasi ini, kami dapat mengidentifikasi kelemahan model dan melakukan penyesuaian

jika diperlukan, seperti dengan memperbaiki model peramalan atau menambahkan variabel yang lebih relevan. Pada akhirnya, evaluasi ini menjadi landasan penting dalam meningkatkan efektivitas peramalan di masa mendatang dan memberikan kepercayaan bagi pengambil kebijakan atau pelaku bisnis dalam menggunakan hasil prediksi harga tersebut.

5.2.1 Minyak Goreng




Figure 8: Peramalan Model DFM Minyak Goreng

Grafik 5 menunjukkan hasil peramalan model Dynamic Factor Model (DFM) untuk 6 periode ke depan pada harga minyak goreng, dengan faktor-faktor yang terstandarisasi (f1 dan f2). Pada grafik ini, garis merah merepresentasikan faktor pertama (f1), sedangkan garis hijau muda merepresentasikan faktor kedua (f2). Sementara itu, garis-garis abu-abu di latar belakang adalah data historis yang terstandarisasi, yang mencakup fluktuasi harga sebelum periode peramalan.

Dari grafik tersebut, dapat dilihat bahwa kedua faktor (f1 dan f2) cukup stabil menjelang akhir periode data historis, menunjukkan bahwa model DFM telah menangkap pola utama dalam data tersebut. Setelah titik waktu ke-75 (yang diindikasikan oleh garis vertikal putus-putus), grafik menunjukkan peramalan untuk 6 periode ke depan. Garis peramalan (baik untuk f1 maupun f2) cenderung mendekati nilai rata-rata, tanpa fluktuasi yang signifikan. Hal ini mengindikasikan bahwa model DFM memperkirakan stabilitas pada harga minyak goreng selama periode peramalan, dengan sedikit atau tanpa volatilitas yang ekstrem.

Interpretasi ini menunjukkan bahwa model DFM tidak mendeteksi adanya gangguan besar atau pergeseran tren dalam jangka pendek, yang bisa mengindikasikan bahwa pasar untuk minyak goreng diperkirakan akan stabil dalam waktu dekat, berdasarkan pola data historis yang ada. Meskipun demikian, penting untuk tetap mempertimbangkan faktor eksternal atau kejutan pasar yang tidak ditangkap oleh model, yang mungkin bisa mempengaruhi peramalan ini di dunia nyata.

Table 16: Tabel Harga dan Harga Peramalan Minyak Goreng Curah Kemasan Curah.

Tanggal	Harga (Rp)	Harga Peramalan (Rp)	Abs Error (Rp)	Pct Error (%)
2024-04-30	16,734.83	16,700.03	34.80	0.21
2024-05-31	16,687.64	16,773.18	85.54	0.51
2024-06-30	16,632.37	16,858.95	226.58	1.34
2024-07-31	16,744.32	16,944.63	200.31	1.18
2024-08-31	16,924.59	17,028.52	103.94	0.61
2024-09-30	17,098.44	17,112.75	14.31	0.08

Tabel 16 menunjukkan perbandingan antara harga aktual minyak goreng curah kemasan curah dengan hasil peramalan untuk periode April hingga September 2024. Kolom pertama menampilkan tanggal observasi bulanan, sedangkan kolom kedua dan ketiga masing-masing berisi harga aktual dan harga yang diprediksi. Selisih antara kedua nilai tersebut ditunjukkan dalam kolom "Abs Error (Rp)", yang menggambarkan absolute error dalam satuan rupiah. Selain itu, kolom terakhir, "Pct Error (%)", menunjukkan persentase kesalahan peramalan terhadap harga aktual.

Dari tabel tersebut, terlihat bahwa error absolut terbesar terjadi pada bulan Juni 2024, dengan selisih Rp226,58 atau 1,34%, sedangkan error terkecil terjadi pada September 2024 dengan selisih hanya Rp14,31 atau 0,08%. Secara keseluruhan, model peramalan cukup akurat dengan persentase kesalahan yang bervariasi antara 0,08% hingga 1,34%, menunjukkan bahwa model ini mampu memberikan prediksi yang mendekati harga aktual, meskipun terdapat beberapa fluktuasi kecil dalam kesalahan peramalan. Hasil ini menunjukkan potensi stabilitas harga yang diramalkan oleh model, dengan fluktuasi yang relatif terkendali selama periode peramalan.

Table 17: Tabel Harga dan Harga Peramalan Minyak Goreng Sawit Kemasan Premium.

Tanggal	Harga (Rp)	Harga Peramalan (Rp)	Abs Error (Rp)	Pct Error (%)
2024-04-30	21,630.16	21,656.47	26.31	0.12
2024-05-31	21,600.18	21,743.36	143.18	0.66
2024-06-30	21,552.52	21,854.08	301.55	1.38
2024-07-31	21,598.74	21,963.62	364.87	1.66
2024-08-31	21,678.37	22,069.40	391.03	1.77
2024-09-30	21,684.23	22,175.67	491.44	2.22

Tabel 17 menyajikan perbandingan antara harga aktual dan harga peramalan untuk minyak goreng sawit kemasan premium pada periode April hingga September 2024. Kolom pertama menunjukkan tanggal observasi setiap bulannya, sementara kolom kedua dan ketiga masing-masing mencantumkan harga aktual dan hasil peramalan dalam satuan rupiah. Kolom keempat berisi "Abs Error (Rp)" yang menunjukkan selisih absolut antara harga aktual dan peramalan, sedangkan kolom terakhir

menampilkan persentase kesalahan peramalan terhadap harga aktual dalam "Pct Error (%)".

Dari tabel tersebut, terlihat bahwa kesalahan absolut dan persentase kesalahan peramalan cenderung meningkat seiring berjalannya waktu. Pada bulan April 2024, absolute error relatif kecil sebesar Rp26,31 atau 0,12%. Namun, pada September 2024, kesalahan absolut meningkat menjadi Rp491,44 dengan persentase kesalahan 2,22%. Hal ini menunjukkan bahwa meskipun peramalan model cukup akurat pada awal periode peramalan, tingkat kesalahan cenderung meningkat pada bulan-bulan berikutnya. Meskipun begitu, dengan persentase kesalahan yang masih berada di bawah 2,5%, model ini dianggap memberikan prediksi yang cukup baik untuk tren harga minyak goreng sawit kemasan premium.

5.2.2 Tepung Terigu




Figure 9: Peramalan Model DFM Tepung Terigu

Grafik 6 menunjukkan hasil peramalan model Dynamic Factor Model (DFM) untuk tepung terigu dengan proyeksi ke depan selama 6 periode. Grafik ini menampilkan tiga faktor terstandarisasi, yaitu f1 (garis merah), f2 (garis hijau), dan f3 (garis biru), yang mewakili faktor-faktor laten dalam model DFM. Garis vertikal putus-putus menunjukkan batas antara data observasi historis (sebelum garis putus-putus) dan hasil peramalan (setelah garis putus-putus).

Pada bagian data historis (periode sebelum waktu ke-75), faktor-faktor terlihat relatif stabil dengan sedikit fluktuasi, menunjukkan bahwa faktor-faktor ini mencerminkan perubahan harga historis dengan

baik. Setelah garis vertikal (periode waktu ke depan), ketiga faktor menunjukkan konvergensi menuju nilai yang relatif stabil mendekati nol, yang mengindikasikan bahwa model DFM memprediksi sedikit perubahan signifikan untuk periode-periode ke depan.

Faktor f_1 , f_2 , dan f_3 menunjukkan pola yang serupa dalam proyeksi mereka, meskipun ada sedikit variasi di sekitar waktu ke-75. Setelah titik ini, ketiga faktor stabil secara bersamaan, menunjukkan bahwa model DFM memberikan proyeksi yang konsisten untuk ketiga faktor tersebut. Fluktuasi kecil yang terlihat di dekat batas antara data historis dan proyeksi bisa mengindikasikan respons model terhadap variasi kecil pada data akhir periode historis.

Secara keseluruhan, plot ini menunjukkan bahwa model DFM memberikan prediksi yang cukup stabil untuk tepung terigu, dengan hasil yang mengindikasikan tidak adanya lonjakan atau penurunan harga yang signifikan dalam proyeksi enam periode ke depan. Hasil ini dapat digunakan sebagai indikasi bahwa harga tepung terigu diperkirakan akan tetap relatif stabil dalam waktu dekat.

Table 18: Tabel Harga dan Harga Peramalan Tepung Terigu.

Tanggal	Harga (Rp)	Harga Peramalan (Rp)	Abs Error (Rp)	Pct Error (%)
2024-04-30	13,956.23	14,013.18	56.95	0.41
2024-05-31	13,950.00	14,090.83	140.84	1.00
2024-06-30	13,954.41	14,172.06	217.65	1.54
2024-07-31	13,909.47	14,254.70	345.23	2.42
2024-08-31	13,856.34	14,338.49	482.15	3.36
2024-09-30	13,848.36	14,423.00	574.64	3.98

Tabel di atas menunjukkan perbandingan antara harga aktual tepung terigu dan harga peramalan dari bulan April 2024 hingga September 2024, serta error absolut dan persentase error untuk setiap periode. Perbedaan antara harga aktual dan harga peramalan, yang diukur melalui error absolut (Abs Error), bervariasi dari nilai yang relatif kecil pada awal periode (seperti Rp 56.95 pada April 2024) hingga nilai yang lebih besar di akhir periode (seperti Rp 574.64 pada September 2024). Persentase error (Pct Error) juga meningkat seiring waktu, mulai dari 0.41% di bulan April 2024 hingga mencapai 3.98% di bulan September 2024.

Ini menunjukkan bahwa model peramalan berfungsi dengan cukup baik di awal periode, dengan kesalahan yang relatif kecil, namun seiring berjalannya waktu, kesalahan prediksi mulai meningkat, baik dalam hal absolut maupun persentase. Peningkatan ini dapat disebabkan oleh berbagai faktor, seperti ketidakpastian yang meningkat atau dinamika pasar yang lebih kompleks dalam jangka waktu yang lebih panjang.

6 Kesimpulan dan Keterbatasan Penelitian

6.1 Kesimpulan

Dari analisis yang dilakukan menggunakan model Dynamic Factor Model (DFM), kami telah berhasil melakukan peramalan harga untuk tiga komoditas penting di Indonesia, yaitu minyak goreng curah, minyak goreng sawit kemasan premium, dan tepung terigu. Berikut adalah beberapa poin penting dari hasil analisis dan peramalan:

Pertama, hasil peramalan untuk harga minyak goreng curah menunjukkan bahwa model DFM dapat menangkap pola harga yang stabil, dengan persentase error yang relatif kecil, berkisar antara 0.08% hingga 1.34%. Ini menunjukkan bahwa harga minyak goreng curah diperkirakan akan stabil selama periode peramalan, tanpa adanya fluktuasi besar yang diantisipasi oleh model.

Kedua, pada peramalan harga minyak goreng sawit kemasan premium, model DFM juga mampu memberikan prediksi yang cukup akurat, terutama pada awal periode peramalan. Namun, error absolut dan persentase error cenderung meningkat seiring berjalannya waktu, mencapai 2.22% pada bulan terakhir. Meskipun demikian, tingkat kesalahan masih berada pada level yang dapat diterima untuk sebagian besar aplikasi praktis.

Ketiga, peramalan harga tepung terigu menunjukkan peningkatan kesalahan peramalan yang lebih signifikan, dengan persentase error yang mencapai 3.98% pada akhir periode peramalan. Hal ini menunjukkan bahwa meskipun model DFM bekerja dengan baik untuk beberapa periode awal, tingkat ketidakpastian dalam peramalan harga tepung terigu meningkat seiring dengan panjangnya horizon prediksi.

Secara keseluruhan, model Dynamic Factor Model (DFM) yang digunakan dalam analisis ini telah berhasil memberikan prediksi harga yang relatif akurat untuk ketiga komoditas. Meskipun terdapat peningkatan kesalahan peramalan seiring berjalannya waktu, model ini mampu menangkap tren dan pola harga yang penting, terutama untuk peramalan jangka pendek. Dalam aplikasi praktis, hasil peramalan ini dapat digunakan sebagai panduan untuk pengambilan keputusan dalam pasar minyak goreng dan tepung terigu, baik oleh pemerintah maupun oleh pelaku bisnis.

6.2 Keterbatasan Penelitian

Salah satu keterbatasan dalam penelitian ini adalah kami belum melakukan time series cross validation karena keterbatasan waktu yang ada dalam kontrak kami. Time series cross validation adalah metode validasi yang penting dalam analisis deret waktu karena data bersifat temporal dan memiliki ketergantungan antarperiode. Berbeda dengan cross validation biasa yang dapat memotong data secara acak menjadi beberapa bagian, time series cross validation memastikan bahwa urutan waktu tetap dipertahankan. Dalam metode ini, model dilatih pada data dari masa lalu dan divalidasi pada data masa depan dalam rentang waktu yang berbeda secara berurutan. Salah satu pendekatan yang umum digunakan adalah rolling window atau expanding window, di mana data dibagi menjadi beberapa sub-set yang mengikuti urutan waktu untuk memprediksi periode yang akan datang, kemudian diulangi dengan menambah ukuran data pelatihan secara bertahap.

Proses ini memberikan gambaran yang lebih realistis tentang performa model ketika digunakan pada data baru dan memungkinkan model diuji dalam kondisi yang lebih mendekati kenyataan. Namun, karena keterbatasan waktu dalam kontrak kami, prosedur ini belum bisa kami terapkan dalam studi ini. Oleh karena itu, ada kemungkinan bahwa model kami belum diuji secara optimal untuk melihat performa prediktifnya di berbagai situasi waktu. Di masa mendatang, penerapan time series cross validation sangat disarankan untuk mengatasi keterbatasan ini dan meningkatkan keakuratan prediksi.

Peneliti menemukan bahwa terdapat kategori minyak goreng dengan observasi yang terbatas yaitu “Minyak Goreng, Minyakita” di dalam dataset. Namun, untuk data tersebut hanya tersedia di periode tahun 2024 dan 2023. Kemudian, peneliti juga mengalami kesulitan untuk mendefinisikan atau

memasukan produk tersebut ke kategori lain. Oleh karena itu, peneliti memutuskan untuk tidak menggunakan data untuk kedua produk tersebut.

Peneliti juga melakukan penyesuaian kategori data untuk provinsi. Hal ini dikarenakan untuk data di tahun 2024 telah dikategorisasi untuk 38 provinsi. Peneliti kemudian menggabungkan data Papua Pegunungan, Papua Tengah, dan Papua Selatan ke dalam data Papua serta menggabungkan data Papua Barat Daya ke dalam data Papua Barat.

Peneliti berencana untuk mengukur nilai autokorelasi per provinsi yang diperoleh dari data di level Kabupaten/ Kota, sehingga dapat diperoleh pengukuran keeratan hubungan di level sub-wilayah. Namun, data yang tersedia tidak menggambarkan keseluruhan Kabupaten/Kota ataupun adanya inkonsistensi (perubahan) Kabupaten/Kota acuan. Sebagai contoh, untuk data Tepung Terigu di Provinsi Aceh dari 2018-2021 hanya berbasis data dari 3 Kabupaten/Kota, yaitu: 1) Kota Lhokseumawe; 2) Kota Banda Aceh; dan 3) Kabupaten Aceh Barat. Sedangkan, sejak tahun 2022, data tersebut mencakup 11 Kabupaten/Kota lain di Provinsi Aceh. Dari temuan ini, peneliti memutuskan untuk tidak mengukur tingkat keeratan di level Kabupaten/Kota.

6.3 Rekomendasi Penelitian di Masa Depan

Berdasarkan permintaan untuk menambahkan data yang relevan dengan isu geopolitik global, ada beberapa rekomendasi yang dapat dipertimbangkan untuk memperkaya analisis menggunakan Dynamic Factor Model (DFM). Pertama, data terkait harga energi internasional seperti harga minyak mentah (Brent dan WTI) dapat memberikan konteks terhadap fluktuasi biaya produksi dan distribusi, terutama karena minyak goreng dan tepung terigu memiliki keterkaitan dengan energi dalam proses logistiknya. Kedua, indeks ketidakpastian kebijakan ekonomi global (Global Economic Policy Uncertainty Index) dapat digunakan untuk menangkap dampak tidak langsung dari ketegangan geopolitik terhadap perdagangan internasional dan harga komoditas.

Selanjutnya, data terkait indikator global perdagangan seperti Baltic Dry Index dapat memberikan informasi tambahan mengenai biaya pengiriman internasional yang sering kali terdampak oleh ketidakstabilan geopolitik. Selain itu, perubahan dalam volume atau nilai perdagangan bilateral antara Indonesia dengan negara mitra utama untuk minyak goreng dan tepung terigu, khususnya negara yang terlibat dalam konflik geopolitik, juga dapat menjadi sumber data yang berharga.

Tidak kalah penting, data indeks risiko geopolitik global (Global Geopolitical Risk Index) dapat dimanfaatkan untuk mencerminkan dampak ketegangan internasional terhadap sentimen pasar dan perdagangan. Data lain yang juga relevan adalah indikator ketahanan pangan global (Global Food Security Index) untuk mengukur dampak geopolitik terhadap ketersediaan dan harga pangan secara internasional. Terakhir, data alokasi subsidi atau tarif perdagangan pada komoditas terkait di negara-negara pengimpor dan pengekspor utama dapat menjadi tambahan untuk menangkap dinamika kebijakan yang dipengaruhi oleh isu geopolitik.

References

- Bai, J. & Ng, S., 2008. Large dimensional factor analysis. *Foundations and Trends in Econometrics*, 3(2), pp.89–163.
- Bai, J. & Wang, P., 2016. Econometric analysis of large factor models. *Annual Review of Economics*, 8, pp.53–80.
- Barhoumi, K., Darné, O. & Ferrara, L., 2014. Dynamic factor models: A review of the literature. *OECD Journal: Journal of Business Cycle Measurement and Analysis*, 2013(2), pp.73–107.
- Barigozzi, M., 2018. *Dynamic factor models: Lecture notes*. London: London School of Economics.
- Bivand, R., Müller, W.G. & Reeder, M., 2009. Power calculations for global and local Morán's I. *Computational Statistics & Data Analysis*, 53(8), pp.2859–2872.
- Breitung, J. & Eickmeier, S., 2006. Dynamic factor models. *Allgemeines Statistisches Archiv*, 90(1), pp.27–42.
- Burns, A.F. & Mitchell, W.C., 1946. *Measuring business cycles*. New York: NBER.
- Chamberlain, G., 1983. Funds, factors, and diversification in arbitrage pricing models. *Econometrica*, 51(5), pp.1305–1323.
- Chamberlain, G. & Rothschild, M., 1983. Arbitrage, factor structure, and mean-variance analysis on large asset markets. *Econometrica*, 51(5), pp.1281–1304.
- Conceição, P., Galbraith, J.K. & Bradford, P., 2001. The Theil Index in sequences of nested and hierarchic grouping structures: Implications for the measurement of inequality through time, with data aggregated at different levels of industrial classification. *Eastern Economic Journal*, 27(4), pp.491–514.
- Darity, W. & Deshpande, A., 2000. Intergroup economic inequality across countries: An introductory essay. *Review of Social Economy*, 58(3), pp.273–276.
- Diebold, F.X., 2003. Big data dynamic factor models for macroeconomic measurement and forecasting. In Dewatripont, L.H.M. & Turnovsky, S. (eds.) *Advances in Economics and Econometrics: Theory and Applications, Eighth World Congress of the Econometric Society*, pp.115–122.
- Elhorst, J.P., 2014. *Spatial Econometrics: From Cross-Sectional Data to Spatial Panels*. Springer, Berlin, Heidelberg.
- Geweke, J., 1977. The dynamic factor analysis of economic time series. In Aigner, D.J. & Goldberger, A.S. (eds.) *Latent variables in socio-economic models*. Amsterdam: North Holland.
- LeSage, P. & Pace, R.K., 2009. *Introduction to Spatial Econometrics*. United Kingdom: CRC Press.
- Lütkepohl, H., 2014. *Structural vector autoregressive analysis in a data rich environment: A survey*. Berlin: Humboldt University.
- Marchetti, S. & Tzavidis, N., 2021. Robust estimation of the Theil index and the Gini coefficient for small areas. *Journal of Official Statistics*, 37, pp.955–979.
- Sargent, T.J. & Sims, C.A., 1977. Business cycle modeling without pretending to have too much a priori economic theory. *New Methods in Business Cycle Research*, 1, pp.145–168.
- Spearman, C., 1904. General intelligence objectively determined and measured. *The American Journal of Psychology*, 15(2), pp.201–292.
- Stock, J.H. & Watson, M., 1989. New indexes of coincident and leading economic indicators. *NBER Macroeconomics Annual*, 4, pp.351–394.

- Stock, J.H. & Watson, M., 1991. A probability model of the coincident economic indicators. In *Leading Economic Indicators: New Approaches and Forecasting Records*, pp.63–90.
- Stock, J.H. & Watson, M.W., 1993. A procedure for predicting recessions with leading indicators: Econometric issues and recent experience. In *Business cycles, indicators and forecasting*. Chicago: University of Chicago Press, pp.95–156.
- Stock, J.H. & Watson, M., 2006. Forecasting with many predictors. *Handbook of Economic Forecasting*, 1, p.515.
- Stock, J.H. & Watson, M.W., 2011. Dynamic factor models. In *Handbook on Economic Forecasting*. Oxford: Oxford University Press.
- Stock, J.H. & Watson, M.W., 2016. Dynamic factor models, factor-augmented vector autoregressions, and structural vector autoregressions in macroeconomics. *Handbook of Macroeconomics*, 2, pp.415–525.
- Xu, J. et al., 2004. Regional economic disparities in China and their evolution from 1952 to 2000: Evidence by Theil coefficient based on comparable prices. *Advances in Spatial Analysis and Decision Making*, pp.155–165.
- Hauzenberger, N., Huber, F., & Klieber, K., 2023. Real-time inflation forecasting using non-linear dimension reduction techniques. *International Journal of Forecasting*, 39(2), pp.901–921.
- Araujo, G. S., & Gaglianone, W. P., 2023. Machine learning methods for inflation forecasting in Brazil: New contenders versus classical models. *Latin American Journal of Central Banking*, 4(2), 100087.
- Almosova, A., & Andresen, N., 2023. Nonlinear inflation forecasting with recurrent neural networks. *Journal of Forecasting*, 42(2), pp.240–259.
- Barkan, O., Benchimol, J., Caspi, I., Cohen, E., Hammer, A., & Koenigstein, N., 2023. Forecasting CPI inflation components with hierarchical recurrent neural networks. *International Journal of Forecasting*, 39(3), pp.1145–1162.
- Cornand, C., & Hubert, P., 2020. On the external validity of experimental inflation forecasts: A comparison with five categories of field expectations. *Journal of Economic Dynamics and Control*, 110, 103746.
- McKnight, S., Mihailov, A., & Rumler, F., 2020. Inflation forecasting using the New Keynesian Phillips Curve with a time-varying trend. *Economic Modelling*, 87, pp.
- McKnight, S., Mihailov, A., & Rumler, F., 2020. Inflation forecasting using the New Keynesian Phillips Curve with a time-varying trend. *Economic Modelling*, 87, pp.383–393.
- Aparicio, D., & Bertolotto, M. I., 2020. Forecasting inflation with online prices. *International Journal of Forecasting*, 36(2), pp.232–247.
- Zhang, B., Chan, J. C., & Cross, J. L., 2020. Stochastic volatility models with ARMA innovations: An application to G7 inflation forecasts. *International Journal of Forecasting*, 36(4), pp.1318–1328.
- Medeiros, M. C., Vasconcelos, G. F., Veiga, À., & Zilberman, E., 2021. Forecasting inflation in a data-rich environment: the benefits of machine learning methods. *Journal of Business & Economic Statistics*, 39(1), pp.98–119.
- Mertens, E., & Nason, J. M., 2020. Inflation and professional forecast dynamics: An evaluation of stickiness, persistence, and volatility. *Quantitative Economics*, 11(4), pp.1485–1520.

- Nasir, M. A., 2020. Forecasting inflation under uncertainty: The forgotten dog and the frisbee. *Technological Forecasting and Social Change*, 158, 120172.
- Nason, J. M., & Smith, G. W., 2021. Measuring the slowly evolving trend in US inflation with professional forecasts. *Journal of Applied Econometrics*, 36(1), pp.1–17.
- Bañbura, M., & Bobeica, E., 2023. Does the Phillips curve help to forecast euro area inflation? *International Journal of Forecasting*, 39(1), pp.364–390.
- Macias, P., Stelmasiak, D., & Szafranek, K., 2023. Nowcasting food inflation with a massive amount of online prices. *International Journal of Forecasting*, 39(2), pp.809–826.
- Eickmeier, S., & Ziegler, C., 2008. How successful are dynamic factor models at forecasting output and inflation? A meta-analytic approach. *Journal of Forecasting*, 27(3), pp.237–265.
- Wang, L., Feng, J., Sui, X., Chu, X., & Mu, W., 2020. Agricultural product price forecasting methods: research advances and trend. *British Food Journal*, 122(7), pp.2121–2138.

7 Appendix

7.1 Minyak Goreng

7.1.1 Daftar variabel yang digunakan dalam Model

Daftar variabel berada di folder Metada github.

7.1.2 Simulasi rank dan lag

Hasil simulasi berada di folder 'Laporan/Robustness Check/Robustness Check Training Migor.xlsx' di github.

7.1.3 Local Moran

7.2 Tepung Terigu

7.2.1 Daftar variabel yang digunakan dalam Model

Daftar variabel berada di folder Metada github.

7.2.2 Simulasi rank dan lag

Hasil simulasi berada di folder 'Laporan/Robustness Check/Robustness Check Training TT.xlsx' di github.

7.2.3 Local Moran

Table 19: Local Moran Rerata Harga Minyak Goreng Sawit Kemasan Premium antar Provinsi, 2018-2023

Provinsi	2018	2019	2020	2021	2022	2023
Aceh	-0.0226	-0.0798	-0.0149	-0.0562	-0.0202	-0.0332
Bali	-0.0263	-0.0135	-0.0338	-0.0967	0.1218	0.2287
Bangka Belitung	-0.0851	-0.1850	-0.4606	-0.5258	0.2911	0.2365
Banten	0.6125	0.3890	0.3848	0.2355	0.2350	0.4528
Bengkulu	0.2874	0.5277	0.3415	0.1904	0.2334	0.2435
Gorontalo	0.2457	0.2813	0.2651	0.1395	0.0315	0.0167
Jakarta	0.5287	0.3205	0.4575	0.4951	-0.2481	0.2089
Jambi	0.3495	0.7022	0.5511	0.4891	0.4368	0.4303
Jawa Barat	0.3942	0.2076	0.3610	0.3348	0.2639	0.4196
Jawa Tengah	0.5839	0.4929	0.5079	0.2703	0.4142	0.5098
Jawa Timur	0.3092	0.2953	0.3107	0.1837	0.2486	0.2766
Kalimantan Barat	0.0186	-0.0202	-0.0294	-0.1208	-0.0838	-0.0765
Kalimantan Selatan	0.0053	-0.0023	0.0197	0.0083	-0.0086	0.0026
Kalimantan Tengah	-0.0775	-0.1074	0.0083	-0.0100	-0.0185	-0.0342
Kalimantan Timur	-0.0082	-0.0446	-0.0790	-0.0516	0.0153	0.0630
Kalimantan Utara	-0.1567	-0.0077	-0.0629	-0.0166	0.0063	0.0481
Kepulauan Riau	-0.0707	-0.1380	0.0761	0.1625	0.2668	0.2674
Lampung	0.3049	0.2217	0.4501	0.4826	0.0989	0.2592
Maluku	0.4234	0.5012	0.4347	0.3176	0.4467	0.4544
Maluku Utara	0.5208	0.5189	0.5290	0.4172	0.4093	0.3611
Nusa Tenggara Barat	-0.0002	0.0027	0.0036	-0.0212	0.0050	0.0564
Nusa Tenggara Timur	0.0168	0.0546	0.0640	0.0429	0.1218	0.0030
Papua	0.5894	0.5163	0.5773	0.4962	0.4553	0.6937
Papua Barat	0.7959	0.6893	0.5795	0.6459	0.5874	0.6457
Riau	0.2195	0.3501	0.3004	0.2386	0.2003	0.2243
Sulawesi Barat	0.0167	0.0340	0.0669	0.0270	0.1383	0.0377
Sulawesi Selatan	0.0440	-0.0310	0.0295	-0.0332	0.1856	0.0334
Sulawesi Tengah	0.1511	0.1121	0.2102	0.0232	0.0727	-0.0738
Sulawesi Tenggara	0.0392	0.0593	0.1156	0.1009	0.2918	0.0427
Sulawesi Utara	0.2233	0.2608	0.3333	0.1797	0.0385	0.2045
Sumatera Barat	0.1231	0.2390	0.1487	0.0358	0.2751	0.3681
Sumatera Selatan	0.4719	0.4807	0.5091	0.6107	0.2834	0.2958
Sumatera Utara	-0.0578	-0.0366	-0.0651	-0.0369	0.0187	-0.0686
Yogyakarta	0.7088	0.6366	0.5717	0.2594	0.4466	0.5643

Table 20: Local Moran Rerata Harga Minyak Goreng Curah Kemasan Curah antar Provinsi, 2018-2023

Provinsi	2018	2019	2020	2021	2022	2023
Aceh	0.2453	0.1412	0.0161	0.0017	0.1041	0.2308
Bali	0.0179	0.0507	0.0065	-0.0042	0.0087	0.0365
Bangka Belitung	-0.3141	-0.1181	0.0262	-0.0655	0.0332	0.0791
Banten	0.1481	0.1416	0.0029	0.0111	0.1298	0.2881
Bengkulu	0.3523	0.2307	0.0338	-0.0006	0.0764	0.1162
Gorontalo	0.1364	0.1349	0.0369	-0.0478	0.0116	0.1446
Jakarta	-0.0347	-0.0109	-0.0168	0.0004	0.1107	0.2106
Jambi	0.4080	0.2834	0.0668	-0.0306	0.0534	0.1483
Jawa Barat	0.0191	0.0610	0.0027	0.0220	0.0767	0.1602
Jawa Tengah	0.1045	0.1547	0.0243	0.0883	0.1191	0.1896
Jawa Timur	0.1044	0.1120	0.0090	0.0121	0.0546	0.0963
Kalimantan Barat	0.0672	0.0279	-0.0431	-0.0657	-0.0465	-0.0111
Kalimantan Selatan	-0.0023	0.0090	0.0184	0.0074	0.0074	0.0255
Kalimantan Tengah	0.0420	0.0245	0.0464	0.0522	-0.0125	0.0359
Kalimantan Timur	0.0539	0.0291	0.0343	0.1903	0.0524	-0.0321
Kalimantan Utara	0.0333	0.0085	-0.2698	-0.3283	-0.3372	-0.1296
Kepulauan Riau	0.1479	0.0960	0.0208	0.0001	0.0649	0.1880
Lampung	0.1818	0.1274	-0.0090	0.0081	0.0519	0.2065
Maluku	0.5380	-0.4123	-0.6443	0.0349	-0.0788	-0.2938
Maluku Utara	0.3307	0.2450	0.0402	0.0017	0.1827	0.5987
Nusa Tenggara Barat	0.0035	0.0046	0.0016	-0.0072	-0.0132	-0.0140
Nusa Tenggara Timur	0.0245	-0.0270	-0.0028	-0.0098	-0.0155	0.0215
Papua	0.5905	0.3118	0.1003	0.0445	0.1229	0.4862
Papua Barat	0.7446	0.3428	-0.0159	0.0607	0.3213	0.6253
Riau	0.3508	0.1707	-0.0060	-0.0076	0.0792	0.2848
Sulawesi Barat	-0.0048	0.0344	0.0062	0.0137	-0.0092	-0.0236
Sulawesi Selatan	-0.0091	-0.0017	-0.0030	-0.0183	0.0015	-0.0355
Sulawesi Tengah	0.0021	0.0803	0.0206	-0.0210	0.0203	0.0431
Sulawesi Tenggara	-0.1589	-0.0578	-0.0486	-0.0293	0.0396	0.0616
Sulawesi Utara	0.0579	0.0970	0.0361	0.0030	0.0586	0.2564
Sumatera Barat	0.4584	0.1846	0.0221	0.0006	0.0960	0.2141
Sumatera Selatan	0.3056	0.1689	0.0225	-0.0273	0.0424	0.0781
Sumatera Utara	0.3180	0.1034	0.0038	0.0026	0.0837	0.2502
Yogyakarta	0.1523	0.2039	0.0239	0.0894	0.1111	0.1523

Table 21: Local Moran Rerata Harga Tepung Terigu tahunan antar Provinsi, 2018-2023

Provinsi	2018	2019	2020	2021	2022	2023
Aceh	-0.0075	0.0137	-0.0015	-0.0262	0.0788	0.0085
Bali	0.1445	0.0160	0.1287	0.1995	0.2461	0.0542
Bangka Belitung	0.0137	-0.0369	0.1132	0.0824	0.1366	0.1787
Banten	0.0832	0.1408	0.2547	0.3650	0.4824	0.0295
Bengkulu	-1.0363	-0.9729	-1.0811	-0.6100	-0.3491	-0.2658
Gorontalo	-0.0054	-0.0379	-0.0326	-0.0347	0.1619	0.0185
Jakarta	0.0712	0.1317	0.2450	0.4096	0.4853	0.1918
Jambi	-0.2559	-0.1043	-0.1342	-0.0452	0.1295	0.1756
Jawa Barat	0.2123	0.3135	0.3051	0.5998	0.9037	0.4057
Jawa Tengah	0.4630	0.4286	0.4360	0.7373	0.7818	0.6505
Jawa Timur	0.2614	0.1777	0.2564	0.4021	0.6340	0.2705
Kalimantan Barat	-0.0186	-0.0188	0.0353	0.0280	-0.0959	-0.1536
Kalimantan Selatan	0.0194	0.0185	-0.0614	-0.0471	-0.0046	0.0196
Kalimantan Tengah	-0.1420	-0.1525	-0.0540	-0.0578	-0.0102	-0.0267
Kalimantan Timur	-0.0143	0.0421	0.0365	0.0002	0.0670	-0.0600
Kalimantan Utara	-0.0221	0.0280	0.0083	0.0006	0.0913	0.0090
Kepulauan Riau	-0.1688	0.0520	0.1626	0.0208	0.1063	0.2746
Lampung	0.0040	0.1235	0.2435	0.2342	0.1108	0.0620
Maluku	0.0753	0.1255	0.1260	0.2810	0.3376	0.0014
Maluku Utara	0.0619	0.1485	0.1337	0.1854	0.2411	0.1560
Nusa Tenggara Barat	0.0551	-0.0071	-0.0304	-0.0246	0.0350	-0.0589
Nusa Tenggara Timur	0.0184	-0.0471	-0.0434	-0.0483	0.0082	-0.0229
Papua	0.1749	0.2117	0.2525	0.1975	0.2895	0.4134
Papua Barat	0.1955	0.2575	0.2781	0.3529	0.4494	0.4065
Riau	0.0364	0.0077	-0.0593	0.0359	0.0675	0.1054
Sulawesi Barat	-0.1455	-0.0114	0.0342	0.0239	0.1337	-0.0057
Sulawesi Selatan	-0.0198	0.0203	0.0077	0.0559	-0.1283	-0.1251
Sulawesi Tengah	0.0021	-0.0060	-0.0175	0.0829	0.3140	0.0018
Sulawesi Tenggara	-0.0543	0.0017	0.0386	0.1231	0.2262	0.0001
Sulawesi Utara	-0.0073	0.0211	-0.0179	-0.1629	0.3842	0.0598
Sumatera Barat	0.0377	0.0582	0.0346	-0.0042	0.0239	-0.0011
Sumatera Selatan	0.0012	-0.0052	-0.0009	-0.0962	0.1010	0.1016
Sumatera Utara	0.0073	-0.0149	-0.1797	-0.3626	0.0524	-0.3030
Yogyakarta	0.4756	0.3988	0.4507	0.7014	0.5987	0.7354